

修士論文

異分解能衛星画像を統合した 土地被覆分類手法の開発

Development of land cover classification method
integrating multi-resolution satellite images

37-156004 泉 裕一郎

主査：布施 孝志 准教授

副査：羽藤 英二 教授

| 署名 | 日付 | 印 |
|----|----|---|
| 主査 | | |
| 副査 | | |

東京大学 大学院工学系研究科 社会基盤学専攻

2017 年 3 月

論文要旨

土地被覆分類図は都市調査など様々なアプリケーションの基盤情報として活用されている。1972年に地球観測衛星 Landsat 1 が打ち上げられて以来、衛星画像を用いた土地被覆分類に関する研究は活発に行われている。近年では、一般に提供される衛星画像の分解能は数 10cm オーダーとなり、より詳細な土地被覆分類図の作成が可能となった。一方、衛星画像の高分解能化により詳細な地物がノイズとなり従来のピクセルベースの土地分類手法では誤分類を多く引き起こすことになった。そこで、画像の空間的特徴を考慮したオブジェクトベースの土地被覆分類手法が注目されている。ところで、従来の土地被覆分類に関する研究は、単一センサーから得られた個々の衛星画像を用いたものが多かった。しかし、近年の計算機技術の発展、ビッグデータ活用の気運などを背景に、異種衛星画像を統合した土地被覆分類に期待が集まっている。異分解能衛星画像が持つ異なる特徴を組み合わせることにより、それぞれの課題を補完し合うような土地被覆分類が実現することが考えられる。また、異なるセンサーから得られる衛星画像全てを1つのモデル学習時に利用することも可能になるため、モデル学習の安定性向上やより普遍的な特徴抽出の可能性も期待される。そこで本研究の目的は、異分解能衛星画像を統合した土地被覆分類手法の提案および提案手法の適用可能性を検証することとする。

本研究では、まず従来の土地被覆分類の手法と課題を整理し、異分解能衛星画像の統合の優位性を示す。そして提案手法を構築し、その検証を行う。提案手法では、中分解能衛星画像のスペクトル値を、高分解能衛星画像のスペクトル値と空間的特徴を考慮したオブジェクト特徴量を作成し、これらを入力として **SPP-net** を用いて土地被覆分類を行う。**SPP-net** は従来の畳み込みニューラルネットワークを拡張したものであり、異なる大きさの画像に対しても高精度なクラス分類を行うことが可能なことから、異分解能衛星画像の統合に適しているものである。

提案手法の検証では、分解能 0.31m の WorldView-3 による衛星画像、分解能 15m の Terra による衛星画像、JAXA が公開している日本全国土地被覆分類図を用いて行った。これらのデータを基に、3種類のデータセットを作成し、それぞれ4種類の条件で土地被覆分類を行った。また、従来手法と比較するために、最尤推定を用いたピクセルベースの土地被覆分類も行った。その結果、提案手法を用いた土地被覆分類では 74.5% の分類精度が得られ、これは最尤推定を用いたピクセルベースの土地被覆分類の分類精度 68.1% に比べて高い分類精度であった。また、データセットごとの比較をすると、クラスごとのデータ数の偏りを無くす事で分類精度が向上することが明らかとなった。また、本検証では高分解能衛星画像におけるオブジェクト特徴量の付加により分類精度は低下したが、各オブジェクト特徴量を正規化することで分類精度向上の可能性が期待される。

目次

| | | |
|--------------|---------------------------------------|-----------|
| 第 1 章 | 序論 | 1 |
| 1.1 | 研究の背景 | 1 |
| 1.2 | 研究の目的 | 4 |
| 1.3 | 本論文の構成 | 4 |
| 第 2 章 | 土地被覆分類 | 5 |
| 2.1 | 土地被覆分類とは | 5 |
| 2.2 | ピクセルベースの土地被覆分類 | 7 |
| 2.3 | オブジェクトベースの土地被覆分類 | 7 |
| 2.3.1 | セグメンテーション | 8 |
| 2.3.2 | クラス分類 | 10 |
| 2.4 | 土地被覆分類オープンデータ | 11 |
| 第 3 章 | 異分解能衛星画像を統合した土地被覆分類手法の提案 | 13 |
| 3.1 | 概要 | 13 |
| 3.2 | セグメンテーション | 14 |
| 3.2.1 | H 画像の作成 | 15 |
| 3.2.2 | watershed 変換 | 16 |
| 3.2.3 | 領域統合 | 16 |
| 3.2.4 | オブジェクト特徴量の取得 | 18 |
| 3.3 | クラス分類 | 19 |
| 3.3.1 | 畳み込みニューラルネットワーク | 20 |
| 3.3.2 | SPP-net | 21 |
| 第 4 章 | 提案手法の検証 | 23 |
| 4.1 | 検証に用いたデータ | 23 |
| 4.1.1 | Terra 衛星画像 | 23 |
| 4.1.2 | WorldView-3 衛星画像 | 25 |
| 4.1.3 | AVNIR-2 高解像度土地利用被覆図 ver. 16.02 | 27 |
| 4.1.4 | データセットの作成 | 30 |
| 4.2 | 検証に用いた SPP-net の構造 | 30 |
| 4.3 | 予備検証 | 32 |
| 4.3.1 | 検証条件 | 32 |
| 4.3.2 | 検証結果 | 33 |
| 4.4 | 検証 I | 37 |

| | | |
|-------------|---------------------------------|-----------|
| 4.4.1 | データセット | 37 |
| 4.4.2 | 検証条件 | 38 |
| 4.4.3 | 検証結果 | 38 |
| 4.5 | 検証Ⅱ | 40 |
| 4.5.1 | データセット | 41 |
| 4.5.2 | 検証条件 | 41 |
| 4.5.3 | 検証結果 | 41 |
| 4.6 | 検証Ⅲ | 44 |
| 4.6.1 | データセット | 44 |
| 4.6.2 | 検証条件 | 45 |
| 4.6.3 | 検証結果 | 45 |
| 4.7 | 従来手法との比較 | 47 |
| 4.8 | 考察 | 50 |
| 4.8.1 | データセット間の比較 | 51 |
| 4.8.2 | 中分解能衛星画像の有無に関して | 52 |
| 4.8.3 | 高分解能衛星画像のオブジェクト特徴量の有無に関して | 52 |
| 4.8.4 | 従来手法との比較 | 53 |
| 第5章 | 本研究の結論 | 54 |
| 5.1 | 本研究の成果 | 54 |
| 5.2 | 今後の課題 | 56 |
| 参考文献 | | |
| 付録 | | |
| 謝辞 | | |

図 目次

| | |
|--|----|
| 図 1-1 Landsat で撮影された衛星画像とピクセルベースの土地被覆分類図 [伊藤ら 1996] | 1 |
| 図 1-2 WorldView-3 で撮影された分解能約 0.31m の衛星画像 (東京駅周辺) | 2 |
| 図 1-3 Quickbird で撮影された衛星画像とオブジェクトベースの土地被覆分類図 [Myint et al. 2011] | 2 |
| 図 2-1 セグメンテーションの過程[Chen et al. 2008] | 9 |
| 図 3-1 提案手法の概要..... | 14 |
| 図 3-2 セグメンテーションのフローチャート..... | 15 |
| 図 3-3 watershed アルゴリズムの概念図[Vincent et al. 1991]..... | 16 |
| 図 3-4 統合処理のフローチャート[Chen et al. 2008] | 17 |
| 図 3-5 オブジェクト特徴量マップの取得..... | 19 |
| 図 3-6 SPP-net を用いた異分解能衛星画像のクラス分類..... | 20 |
| 図 3-7 画像認識などで一般的に用いられる CNN の構造[岡谷 2015] | 20 |
| 図 3-8 画像の切り出し前後と画像のリサイズ前後..... | 22 |
| 図 3-9 従来の CNN を用いた画像分類 (上) と SPP-net を用いた画像分類 (下) .. | 22 |
| 図 3-10 SPP 層の概略図[He et al.2014] | 22 |
| 図 4-1 本研究で用いた画像 (Terra により撮影) | 24 |
| 図 4-2 本研究で用いた画像 (Terra により撮影) (切り出し後) | 25 |
| 図 4-3 本研究で用いた画像 (WorldView-3 により撮影) | 27 |
| 図 4-4 日本全国の土地被覆分類結果..... | 29 |
| 図 4-5 対象地域の土地被覆分類結果..... | 29 |
| 図 4-6 本検証で用いたネットワーク図 | 31 |
| 図 4-7 予備検証で用いた画像 (WorldView-3 により撮影) | 32 |
| 図 4-8 対象領域の H 画像..... | 33 |
| 図 4-9 対象領域の watershed 変換によるセグメンテーション結果..... | 34 |
| 図 4-10 様々な w_{color} における SP 値と Borsotti 値の関係 | 35 |
| 図 4-11 様々な SP 値における w_{color} と Borsotti 値の関係..... | 35 |
| 図 4-12 領域統合結果 ($w_{color}=0.8$, $w_{shape}=0.2$) | 36 |
| 図 4-13 exp_1~exp_4 における学習経過 | 38 |
| 図 4-14 exp_1~exp_4 のクラス分類精度 | 39 |
| 図 4-15 exp_1~exp_4 のクラス分類結果 | 39 |
| 図 4-16 exp_5~exp_8 における学習経過 | 42 |
| 図 4-17 exp_5~exp_8 におけるクラス分類精度..... | 42 |

| | |
|---------------------------------------|----|
| 図 4-18 exp_5~exp_8 のクラス分類結果 | 43 |
| 図 4-19 exp_9~exp_12 における学習経過 | 45 |
| 図 4-20 exp_9~exp_12 におけるクラス分類精度 | 46 |
| 図 4-21 exp_9~exp_12 のクラス分類結果 | 46 |
| 図 4-22 exp_m1 と exp_m2 のクラス分類結果 | 48 |
| 図 4-23 exp_m3 と exp_m4 のクラス分類結果 | 48 |
| 図 4-24 exp_m5 と exp_m6 のクラス分類結果 | 49 |
| 図 4-25 各検証条件と分類精度一覧 | 50 |
| 図 4-26 各データセットにおける分類精度の比較 | 51 |

表 目次

| | |
|--|----|
| 表 1-1 中分解能衛星画像と高分解能衛星画像の比較 | 3 |
| 表 2-1 衛星画像と航空画像の特徴の比較..... | 6 |
| 表 2-2 マルチスペクトルスキャナーと合成開口レーダーの特徴の比較 | 6 |
| 表 4-1 Terra に搭載されている光学センサーASTER | 23 |
| 表 4-2 本研究で用いた画像の撮影条件（Terra により撮影） | 24 |
| 表 4-3 本研究で用いた画像の撮影条件（Terra により撮影）（切り出し後） | 25 |
| 表 4-4 WorldView-3 に搭載されている光学センサー | 26 |
| 表 4-5 本研究で用いた画像の撮影条件（WorldView-3 により撮影） | 26 |
| 表 4-6 土地被覆分類図のデータ形式..... | 28 |
| 表 4-7 作成したデータセット一覧 | 30 |
| 表 4-8 予備検証で用いた画像の撮影条件（WorldView-3 により撮影） | 32 |
| 表 4-9 予備検証の条件..... | 33 |
| 表 4-10 検証 I で用いたデータセット | 37 |
| 表 4-11 検証 I の検証条件 | 38 |
| 表 4-12 検証 II で用いたデータセット | 41 |
| 表 4-13 検証 II の検証条件 | 41 |
| 表 4-14 検証Ⅲで用いたデータセット | 44 |
| 表 4-15 検証Ⅲの検証条件 | 45 |
| 表 4-16 従来手法の検証条件..... | 47 |
| 表 4-17 各検証条件と分類精度一覧 | 50 |

第1章 序論

1.1 研究の背景

土地被覆分類図は、都市調査[Myint et al. 2011, Vatsavai et al. 2011, 大西ら 2014, 安藤ら 2015], 植生調査[沖ら 2002], 森林管理[小阪ら 2007, 中川ら 2012], 農地管理[Moody et al. 2016], 災害被害把握[三富ら 2002]など様々なアプリケーションの基盤情報として活用されている。1972 年に米国の地球観測衛星 Landsat 1 が打ち上げられて以来、衛星画像を用いた土地被覆分類は衛星リモートセンシング研究の大きなテーマの 1 つであり続けている[Anderson et al. 1976]。Landsat シリーズなどの中分解能地球観測衛星から得られる衛星画像を用いた土地被覆分類では、衛星画像の各ピクセルのスペクトル値を特徴量と考え、教師有り分類や教師無し分類などを用いてピクセル毎にクラス分類を行うピクセルベースの手法に関する研究が活発に行われてきた (図 1-1)。ピクセルベースの土地被覆分類手法では、空間分解能 (以下、分解能と記す) の低さに起因して生じる、1 つのピクセルに複数の土地被覆が混在するミクセルの存在が土地被覆分類の精度を低下させていた。そのため、ミクセルの取り扱いに関しても研究が進められている[沖ら 2002, 須崎ら 2001]。




図 1-1 Landsat で撮影された衛星画像とピクセルベースの土地被覆分類図

[伊藤ら 1996]

2000 年頃になると、センサー技術の発展と法規制の緩和により、一般に提供される衛星画像の分解能は飛躍的に向上した。例えば、2014 年 8 月に打ち上げられ米国の DigitalGlobe 社によって運用されている商業高分解能衛星 WorldView-3 は、分解能約 0.31m の衛星画像を提供している (図 1-2)。この分解能は、地表の車輛を個別に識別できるほどのものであり、従来の航空画像の分解能に匹敵しつつあると言える。また、WorldView-3 の分解能を上回る地球観測衛星の打ち上げプロジェクトも複数進行中であり、今後ますますの衛星画像の高分解能化が期待される。土地被覆分類における高分解能衛星画像の利用は、従来の課題

であったミクセルの影響を減少させた。一方で、自動車や標識などの土地被覆には関係のない地物の影響が無視できなくなり、従来のピクセルベースの土地被覆分類手法を用いると、詳細な地物がノイズとなり誤分類を多く引き起こした。そこで、画像上の空間的な特徴を考慮した、ノイズに頑健な手法の1つとしてオブジェクトベースの土地被覆分類手法が提案された[Blaschke 2010]。この手法では、空間的に近くに存在し類似したスペクトル特性を持つピクセル群を1つのオブジェクトと見なし、各オブジェクトに対して土地被覆の割り当てを行う。Myint ら (2011) は、Quickbird によって撮影された分解能 2.4m の衛星画像を用いて、ピクセルベースおよびオブジェクトベースの土地被覆分類手法の精度比較を行った。その結果、ピクセルベースの手法では分類精度 67.60%であったことに対し、オブジェクトベースの手法では分類精度 90.40%を達成しており、高分解能衛星画像を用いた場合のオブジェクトベースの土地被覆分類の優位性が実証された(図 1-3)。以上の研究により、衛星画像を用いた土地被覆の自動分類への期待は年々増加しているが、依然として専門家の手作業による分類が行われている場合もあり、さらなる分類精度の向上が望まれる。



図 1-2 WorldView-3 で撮影された分解能約 0.31m の衛星画像（東京駅周辺）




図 1-3 Quickbird で撮影された衛星画像とオブジェクトベースの土地被覆分類図

[Myint et al. 2011]

ここで、Landsat などから得られる中分解能衛星画像と WorldView-3 などから得られる高分解能衛星画像の特徴を改めて整理する（表 1-1）。中分解能衛星画像は分解能が低い観測幅が広いことが特徴であることに對し、高分解能衛星画像は分解能が高く詳細な地物が観測できるが観測幅は狭いという特徴を有する。基本的に分解能と観測幅はトレードオフである。また、同一地点を再撮影するまでの時間（以下、時間分解能と記す）については一般的に、中分解能衛星画像は高分解能衛星画像に比べ短い。また、土地被覆分類を行う際には、前述の通り、中分解能衛星画像にはピクセルベースのクラス分類手法が、高分解能衛星画像にはオブジェクトベースのクラス分類手法が適している。

表 1-1 中分解能衛星画像と高分解能衛星画像の比較

| | 中分解能衛星画像 | 高分解能衛星画像 |
|----------|----------------|---------------------|
| 空間分解能 | 数 10 m | 数 10 cm ～ 数 m |
| 観測幅 | 広い | 狭い |
| 時間分解能 | 高い | 低い |
| 衛星例 | Landsat, Terra | IKONOS, WorldView-3 |
| 土地被覆分類手法 | ピクセルベース | オブジェクトベース |

ここで、異なる特徴を持つ中分解能衛星画像と高分解能衛星画像を併用することにより、それぞれの課題を補完し合うような土地被覆分類を行うことが考えられる。従来から、土地被覆分類に関する研究では単一センサーから得られた個々の衛星画像を用いたものが多く、複数のセンサー、すなわち様々な分解能から得られるデータを統合した研究はほとんど行われていない。現在では、計算機技術の発展、ビッグデータ活用の気運、Landsat などの中分解能衛星画像のオープンデータ化などを背景に、土地被覆分類における異種衛星画像の統合が注目されるようになってきている。2016 年には、農作物保険や商品取引における意思決定者にとって有用な土地被覆図を作成するために Planet Labs(分解能 3m)と Landsat 8(分解能 30m)から取得された異なる分解能を持つ衛星画像を組み合わせた土地被覆分類に関する研究が発表され、異分解能衛星画像の利用による精度向上が期待されている[Moody et al. 2016]。しかしながら、この研究では、土地被覆クラスとして農作物のみを対象としているため、その利用は限定的である。また異種衛星画像の統合は、精度向上に留まらず汎用性の高い土地被覆分類モデルの作成への貢献も期待される。従来は1つのセンサーから得られる衛星画像に特化したモデルが作成され、土地被覆分類モデルはセンサーごとに作成する必要があった。しかし、複数のセンサーから得られる衛星画像を統合できるような汎用性の高いモデルの作成が実現すれば、異なるセンサーから得られた衛星画像であっても同一のモデルで土地被覆分類が行うことが可能である。さらには、異なるセンサーから得られる衛星画像全てを1つのモデル学習時に利用することが可能になるため、学習時に利用できる衛星画像を十分に確保でき、モデル学習の安定性向上やより普遍的な特徴抽出の可能性も期待される。

1.2 研究の目的

以上の背景に基づき、本研究の目的は、異分解能衛星画像を統合した土地被覆分類手法の提案および提案手法の適用可能性を検証することとする。具体的には、まず従来の土地被覆分類の手法と課題を整理し、その結果を踏まえ異分解能衛星画像を統合することによる優位性を示した上で手法を提案する。中分解能衛星画像においてはピクセルベース、高分解能衛星画像においてはオブジェクトベースによる土地被覆分類が適しており衛星画像の分解能によって適した土地被覆分類手法が異なるが、両者を併用できる手法の構築を行う。特に異分解能衛星画像を扱うために、SPP-net を援用した手法を構築する。SPP-Net は、通常の畳み込みニューラルネットワークの畳み込み層と全結合層の間に SPP 層を挟むことで、異なる大きさの画像に対しても高い精度でクラス分類を行うことが出来る手法である[He et al. 2014]。手法の適用および検証では、WorldView-3 と Terra から取得された衛星画像と JAXA が公開している土地被覆分類データセットを用いて行う。

1.3 本論文の構成

本論文の構成を示す。第 2 章では土地被覆分類に関する先行研究を整理する。土地被覆分類に関する研究は、ピクセルベースの手法とオブジェクトベースの手法の 2 つに分けて説明を行う。第 3 章では異分解能衛星画像を統合した土地被覆分類手法の提案を行う。第 4 章では第 3 章で説明した提案手法の適用と検証を行う。第 5 章で、本研究の結論と今後の課題を示す。

第2章 土地被覆分類

本章では、まず土地被覆分類の概要を簡単に紹介し、続いて土地被覆分類の手法を説明する。具体的には、これまで多くの研究がなされてきたピクセルベースの土地被覆分類と近年高分解能衛星画像の土地被覆分類において高い精度が報告されているオブジェクトベースの土地被覆分類の順で紹介する。最後に、これまでの土地被覆分類の成果をデータセットとして公開している研究事例をいくつか紹介する。

2.1 土地被覆分類とは

土地被覆分類、調査地域の土地被覆を目的に応じていくつかのクラスに分類することである。土地被覆分類によって作成された土地利用図は、都市調査 [Myint et al. 2011, Vatsavai et al. 2011, 大西ら 2014, 安藤ら 2015], 植生調査 [沖ら 2002], 森林管理 [小阪ら 2007, 中川ら 2012], 農地管理 [Moody et al. 2016], 災害被害把握 [三富ら 2002] など様々なアプリケーションの基盤情報として活用されている。1972年に米国の地球観測衛星 Landsat 1 が打ち上げられて以来、土地被覆分類は衛星リモートセンシング研究の大きなテーマの 1 つであり続けた。衛星画像を基にした土地被覆分類図の作成には、専門家の目視判断による手動分類と計算機による画像処理技術を応用させた自動分類がある。専門家による手動分類は、高精度な土地被覆分類図が作成できるが、高いコストが要求される。一方で、計算機を用いた自動分類は、分類精度は手動分類に劣るが、低コスト・短時間で土地被覆分類図の作成が可能となる。近年のコンピュータビジョンの研究の発展と計算機性能の向上に伴い、様々な自動分類手法が提案されており、コンピュータによる自動分類精度は専門家の手動による分類精度にますます近づいている [Rembold et al. 2004]。

ところで、これまでに行われた土地被覆分類の研究は数多く、研究ごとに入力画像、出力クラス、分類手法などが異なる。

例えば、入力画像と言っても、それが衛星画像なのか航空画像なのかで特性は異なる（表 2-1）。衛星画像は広範囲を周期的に撮影できるが比較的分解能が低い。一方で、航空画像は比較的高分解能であるが撮影領域は局所的で撮影のたびに航空機を飛ばす必要があり周期的な撮影には不向きである。一般的な土地被覆分類においては、広範囲を周期的に撮影することができる衛星画像が多く利用される。広範囲を撮影できる衛星画像は広範囲の土地被覆を調べるのに適している。また、周期的な撮影も、同一地点の衛星画像を複数枚用いて土地被覆の推定精度の向上を目指す研究も行われており、利点となる。これは、田植え期、成長期、収穫期、収穫後で反射スペクトルが異なる水田など、季節性が伴う土地被覆の分類精度の向上に寄与する [竹内 1992, 橋本ら 2014, 大屋ら 2015]。また、同一地点の衛星画像を複数枚用いて、差分画像を取得し、土地被覆の変化抽出を試みる研究も行われている。

[Hussain et al. 2013, Walter 2004] . 一方で、都市部の詳細な土地被覆を調べる際など極めて高い分解能が要求される場合には航空写真を利用する場合もある. また、分解能の低い衛星画像には1ピクセル内に複数の土地被覆が混在するミクセルが含まれるため、ミクセル分解などのミクセルを考慮した分類を行う必要がある [沖ら 2002, 須崎ら 2001] .

また、衛星や航空機は様々な観測センサーによって画像を取得しており、土地被覆分類の目的によって適切な入力画像を選択する必要がある (表 2-2). センサーには、可視光領域付近の波長の反射強度を計測するマルチスペクトルスキャナー (MSS) とマイクロ波の反射強度を計測する合成開口レーダー (SAR) が存在する. MSS は太陽光が地表物に当たって反射した反射波をセンサーで取得する. SAR はレーダー波を発射し、地表物に当たって反射してきた反射波のドップラー変移を数値化し画像に変換する. SAR はレーダー波を発射しているため太陽光がない夜間の撮影も可能であり、さらにマイクロ波領域は雲や大気をよく透過するため、これらの影響を受けづらい. 撮影条件が制限されない SAR は熱帯雨林地域などの MSS の撮影が困難な場所に向いており土地被覆分類への利用事例も増加している [Ferrazzoli et al. 1999, Niu et al. 2013] . MSS と SAR から得られるデータはそれぞれ特徴が異なり、用途によって選択する、もしくは両方を用いる必要がある.

表 2-1 衛星画像と航空画像の特徴の比較

| | 衛星画像 | 航空画像 |
|----|--|---|
| 特徴 | <ul style="list-style-type: none"> ・ 広範囲を撮影 ・ 周期的な撮影 ・ 低分解能 | <ul style="list-style-type: none"> ・ 局所的な撮影 ・ 不定期的な撮影 ・ 高分解能 |

表 2-2 マルチスペクトルスキャナーと合成開口レーダーの特徴の比較

| | マルチスペクトルスキャナー (MSS) | 合成開口レーダー (SAR) |
|----|--|---|
| 特徴 | <ul style="list-style-type: none"> ・ 可視光領域の波 ・ 天候の影響を受ける ・ 夜間の観測が出来ない | <ul style="list-style-type: none"> ・ マイクロ波 ・ 天候の影響を受けない ・ 夜間の観測が可能 |

一方で、土地被覆分類を行う目的によって、出力クラスの設け方は異なる. 例えば、安藤らは都市内の詳細な土地被覆の調査を目的として、樹木、影域、水域、金属、土壌、畑、アスファルト、屋根 (赤)、屋根 (青)、屋根 (黒)、コンクリート、草地の12クラスに分類している [安藤ら 2015]. また、橋本らは日本全国の土地被覆の調査を目的として、土地被覆を水域、都市、水田、畑地、草地、落葉広葉樹、落葉針葉樹、常緑広葉樹、常緑針葉樹、裸地、雪氷の11クラスに分類している [橋本ら 2014]. このように、対象地域や土地被覆分類の目的によって出力クラスは異なる. しかしながら、出力クラスの設定方法には明確な基準がないため、設定される分類クラスは研究によって様々である. そのため、クラス分類精度の比較が困難であるといった問題も存在する [Congalton 1991].

続いて、これまでに行われてきた土地被覆分類手法の説明に移る. 土地被覆分類は、従来、ピクセルごとにクラス分類を行うピクセルベースの土地被覆分類が主流であったが、しか

し、高分解能地球観測衛星の登場や計算機性能の向上に伴い、前処理で画像をいくつかのオブジェクトに分割して、オブジェクトごとにクラス分類を行うオブジェクトベースの土地被覆分類が近年注目されている。次節では、順を追って、ピクセルベースの土地被覆分類とオブジェクトベースの土地被覆分類を説明する。

2.2 ピクセルベースの土地被覆分類

ピクセルベースの土地被覆分類は、衛星画像の各ピクセルのスペクトル値を特徴量として考え、ピクセルごとにクラス分類を行う。ピクセルベースの土地被覆分類は、処理が単純で、計算コストも小さいため、地球観測衛星の登場初期から現在に至るまで多くの研究がされてきた。ピクセルベースの土地被覆分類のクラス分類手法は、教師なし分類、教師付き分類、ルールベースによる分類（エキスパートシステム）のいずれか、もしくは2つ以上を組み合わせた手法によって行われる。具体的な手法の紹介は、オブジェクトベースの土地被覆分類のクラス分類手法と基本的に共通するので次節で説明する。一方で、ピクセル単位でクラス分類を行うため空間的な相関が考慮されていないことに起因して、土地被覆分類結果にごま塩状の微小な誤分類が生じ、十分な精度が得られないという欠点がある。特に高分解能衛星画像を利用した土地被覆分類においては、同一クラスの領域内でも反射特性にばらつきが生じ、正しく分類できないピクセルが増加し、分類精度が低下するという報告もされています[児島ら 1996]。

ピクセル単位のクラス分類手法の欠点を克服するために空間的な相関を考慮に入れた手法がいくつか提案されている。最も有名な手法がオブジェクトベースの土地被覆分類だがこれは次節で説明する。その他にも、クラス分類を行う際に、対象ピクセルのスペクトル値のみを利用するのではなく、対象ピクセルの周辺のピクセルのスペクトル値も特徴量としてクラス分類を行うことで、空間的な相関を考慮するオブジェクトベースの土地被覆分類に近い手法も提案されている[伊東ら 2016]。

2.3 オブジェクトベースの土地被覆分類

オブジェクトベースの土地被覆分類は、ピクセルベースの土地被覆分類とは異なり、オブジェクト単位にクラス分類を行う土地被覆分類手法である。クラス分類を行う前に、画像上で近くに配置し類似した特徴を持つピクセル群を1つのオブジェクトとみなす。この処理はセグメンテーションと呼ばれる。その後に各オブジェクトの特徴量を取得する。その後に、各オブジェクトの特徴量を入力としてクラス分類を行う。この際、オブジェクトの特徴量は大きさ、オブジェクト内の全ピクセルのスペクトルの平均値、オブジェクト内の全ピクセルのスペクトルの分散値などが用いられることが多いが、研究によって様々である[Haralick et al. 1973]。オブジェクトベースの土地被覆は、クラス分類をピクセル単位ではなくオブジェクト単位で行うため、ごま塩状の誤分類が発生せず、高分解能衛星画像の土地被覆分類においても高い分類精度が報告されている。一方で、異なる土地被覆を同一のオブジェクト

と見なすと、後のクラス分類では誤分類を避けられないため、セグメンテーション結果は分類精度の大きく影響する。そのため、ピクセルベースの土地被覆分類結果とオブジェクトベースの土地被覆分類結果を組み合わせる高い分類精度を得る研究も行なわれている [Wang et al. 2004]。

以下では、入力画像をいくつかのオブジェクトに分割するセグメンテーションと、その後のクラス分類について順を追って説明する。

2.3.1 セグメンテーション

セグメンテーションは、オブジェクトベースの土地被覆分類において、クラス分類を行う前に、入力画像全体をいくつかのオブジェクトに分割する処理である。画像上で局所的な同質性基準を満たすピクセル群を1つのオブジェクトとみなすことで、後のクラス分類において高精度が実現する。

オブジェクトベースの土地被覆分類のセグメンテーションにおいて、多くの研究で利用されている手法の1つとして **Multiresolution segmentation** が挙げられる [Darwish et al. 2003, Benz et al. 2004]。この手法は、米国の Trimble 社（旧 Definiens 社）が提供する画像分析ソフトウェア **eCognition** において実装されているセグメンテーションアルゴリズムである。この手法では、まずそれぞれのピクセルを別々のオブジェクトとして考える。続いて、隣接オブジェクト間の類似性を記述する局所的な同質性基準に基づいて、オブジェクトのペアが統合され、より大きなオブジェクトを形成する。同質性基準は、色（スペクトル値）と形（形は **Smoothness** と **Compactness** に分けられる）の組み合わせで表現される。この過程は、ユーザーがあらかじめ設定した閾値（**SP : Scale Parameter**）を同質性基準が超えるまで続けられる。高い閾値を設定した場合、より多くの統合過程を繰り返し、その結果1つ1つのオブジェクトの大きさは大きくなる。この手法は、**SP** 値と同質性基準を決定するいくつかのパラメータを決めるだけで簡単にセグメンテーションを行うことができる。そのため、オブジェクトベースの土地被覆分類におけるセグメンテーションでは多くの場合この手法が用いられる。しかしながら、この手法は一部を除きほとんどのアルゴリズムが非公開となっており、この手法は **eCognition** の利用を前提とする。

一方で、**watershed** 変換を利用したセグメンテーションアルゴリズムも提案されている [Chen et al. 2008]。この手法は、**Multiresolution segmentation** とは異なり、具体的な手法が論文にまとめられており、誰もが利用可能である。この手法では、まず始めに入力画像を基にグレイスケールの微分画像を作成する。その後、作成した微分画像を基に **watershed** 変換を行い、セグメンテーションが行われる。しかし、**watershed** アルゴリズムは過剰なセグメンテーションの生成を避けることができないため、後処理で各オブジェクトを **Multiresolution segmentation** と同様の方法で領域を統合する。

下図は Chen が SPOT 衛星によって撮影した衛星画像に対してセグメンテーションを行った結果である（図 2-1）。図より、**watershed** アルゴリズムの過剰なセグメンテーション化を領域統合処理により補い、適切なセグメンテーションが行われていることがわかる。

Multiresolution segmentation は商用ソフトウェアに実装されているため簡単かつ高速にセグメンテーションを行うことができるが、一部のアルゴリズムが非公開であるため誰もが自由に利用できるわけではなく、手法の改良等も難しい。一方で、watershed 変換を利用したセグメンテーションは、手法が論文を通して公開されているため自由度が高いといったメリットがある。

また、他にも上記の手法を用いてセグメンテーションを階層的に行うなど、さまざまな手法を用いてセグメンテーション結果の改善を目指す試みがある。しかしながら、セグメンテーションの結果を評価する指標が確立していないため、その評価方法はあいまいなものであるといった問題もある[越智 2009]。




図 2-1 セグメンテーションの過程[Chen et al. 2008]

2.3.2 クラス分類

クラス分類は、ピクセルベースの土地被覆分類、オブジェクトベースの土地被覆分類、共通して様々な手法が提案されている。クラス分類には、教師付き分類、教師なし分類、ルールベースによる分類（エキスパートシステム）のいずれか、もしくは2つ以上の併用が考えられる。

教師付き分類では、あらかじめ出力クラスを決定し、正解付きの学習データを用いて分類器の学習を行う。土地被覆分類において用いられる教師付き分類の代表的な手法として、最尤法、ニューラルネットワーク[Heermann et al. 1992, 河邑ら 1995, Mas et al. 2008, Canty 2009, Kavzoglu 2009, Maggiori et al. 2016], SVM[Buddhiraju et al. 2010, Niu et al. 2013, 望月ら 2016], Bagging, Random Forest, Boosting[望月ら 2016]などがあり、他にも数多くのクラス分類手法が提案されており、クラス分類手法ごとの分類精度の比較が行なわれている[Omkar et al. 2007, Rizvi et al. 2011, Qian et al. 2014, 望月ら 2016]。最尤法は、各カテゴリー確率分布を多次元正規分布と仮定して、パラメータを学習データの平均ベクトルと分散共分散行列から推定し、ピクセル・オブジェクトは統計に基づいて最も確からしいカテゴリーに分類される。比較的多くの研究で利用されている手法であるが、カテゴリーの確率分布が多次元正規性に従わないと分類精度が著しく低下するという課題がある。SVM は、学習データに対して2つのクラスを分割するような超平面の中でクラス間のマージンが最大となるような超平面を構成して判別する分類方法である。各クラスの汎化能力が低くならないようにマージンが決定されるため、高精度な分類が可能となる。この手法の利点として、データの特徴の次元が大きくなっても識別精度が良いことが挙げられる。Bagging, Random Forest, Boosting は、複数の弱学習器によって学習を並列して行い、分類結果を統合するアンサンブル学習である。複数の結果を組み合わせる事により、不安定な学習結果を安定させる事が可能となる。なかでも、Random Forest は弱学習器に決定木を用いる、Boosting は弱学習器の重みを逐次更新できるといった特徴が存在する。

教師なし分類では、任意のクラス数数をあらかじめ設定しておくことで、コンピュータが自動的にクラスタリングする手法であり、分類後に各クラスと土地被覆クラスの意味づけを行う。教師無し分類手法には、ISODATA 法、ディシジョンツリー法、最尤法、k-means 法などがある[安藤ら 2015]。

ルールベース分類（エキスパートシステム）では、各土地被覆項目の学習データからスペクトル特性を判読し、各土地被覆項目の特性を分類の1つの条件として加えて設定して分類する手法である。ルールベースの分類と教師あり分類はどちらも学習データが必要となることから、2つを組み合わせる分類を行う場合もある[Myint et al. 2011]。

2.4 土地被覆分類オープンデータ

広範な土地被覆分類図の作成には膨大な時間とコストがかかる。そのため、教師データとして用いるなどのために、土地被覆分類の研究者らがそれぞれに土地被覆分類図を整備するのは非効率です。インターネット上には、これまでに土地被覆分類の研究を行った研究者らによって、研究によって得られたいくつかの土地被覆分類結果が公開されており、研究者はこれらのデータを用いることができます。本節では、公開されているいくつかの土地被覆分類結果を紹介する。

AVNIR-2 高解像度土地利用被覆図 ver. 16.02

AVNIR-2 高解像度土地利用被覆図 ver. 16.02 は、橋下らによって開発された日本の土地被覆分類図である[橋本ら 2014]。データセットは陸地観測技術衛星「だいち」に搭載されている各種センサーにより 2006～2011 年の間に観測された衛星データと行政が公開しているオープンデータを基に作成された。作成された土地被覆分類図のメッシュサイズは約 10m である。分類クラスは、水域、都市、水田、畑地、草地、落葉広葉樹、落葉針葉樹、常緑広葉樹、常緑針葉樹、裸地の 10 個である。このデータセットの全体精度は 76.9%である。

Global Land Cover National Mapping Organization

Global Land Cover by National Mapping Organization (GLCNMO)は、ISCGM（地球地図国際運営委員会）が公開している世界の土地被覆分類図である。データセットは地球観測衛星 Terra/Aqua に搭載された光学センサーMODIS により 2003 年、2008 年、2013 年に観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは約 500m である。分類クラスは、常緑広葉樹林、落葉広葉樹林、常緑針葉樹林、落葉針葉樹林、混合樹林、疎林、かん木、草地、まばらな木またはかん木を含む草地、まばらな植生、畑、水田、農地と他の植生の混合、マングローブ、湿地、裸地（礫、岩）、裸地（砂）、市街地、雪氷、水部の 20 個である。このデータセットの全体精度は 77.9%です。

GlobCover

GlobCover は、ESA（欧州宇宙機関）が公開している世界の土地被覆分類図である。データセットは地球観測衛星 Envisat に搭載された光学センサーMERIS により 2005～2006 年と 2009 年に観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは約 300m である。分類クラスは、農耕地が 2 クラス、農地と植物の混合が 2 クラス、広葉樹林 3 クラス、針葉樹林 3 クラス、森林・低木と草原の混合 3 クラス、まばらな植物、浸水した樹林 2 クラス、浸水した植物、人工表面および関連する地域、裸地、水域、雪氷の 22 個である。このデータセットの全体精度は 67.5%である。

GLC SHARE

GLC SHARE は、GLCN（Global Land Cover Network）が公開している世界の土地被覆分類図である。データセットは Landsat を含む複数の地球観測衛星により 2000～2012 年に観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは

約 1000m である。分類クラスは、人工表面、農耕地、草原、森林、低木、植物、マングローブ、まばらな植物、裸地、雪氷、水域の 11 個である。このデータセットの全体精度は 80.2% である。

MODIS Land Cover

MODIS Land Cover は、GLCF (Global Land Cover Facility) が公開している世界の土地被覆分類図である。データセットは地球観測衛星に搭載されている光学センサー MODIS により 2001~2012 年に観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは約 1000m である。分類クラスは、水域、常緑針葉樹林、常緑広葉樹林、落葉針葉樹林、落葉広葉樹林、混合樹林、低木 2 クラス、サバンナ 2 クラス、草原、湿地、農耕地、年、農地と自然植生の混合、雪氷、裸地の 17 個である。

Global Land Cover 2000

Global Land Cover 2000 (GLC2000) は、EC (欧州委員会) の研究センターが公開している世界の土地被覆分類図である。データセットは地球観測衛星 SPOT に搭載されている光学センサー VEGETATION により 2000 年までに観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは約 1000m である。分類クラスは、森林 6 クラス、低木 2 クラス、草原 2 クラス、湿地 3 クラス、凍原 3 クラス、その他植生 5 クラス、非植生領域 5 クラスの 26 個である。

Global Land Cover Characterization

Global Land Cover Characterization (GLCC) は、USGS (アメリカ地質調査所) が公開している世界の土地被覆分類図である。データセットは地球観測衛星 NOAA に搭載されている光学センサー AVHRR により 1992~1993 年に観測されたデータを用いて作成された。作成された土地被覆分類図のメッシュサイズは約 1000m である。分類クラスは、都市、農地と牧草地 3 クラス、農地と草原の混合、農地と森林の混合、草原、低木、草原と低木の混合、サバンナ、落葉広葉樹林、落葉針葉樹林、常緑広葉樹林、常緑針葉樹林、混合林、水域、湿地 2 クラス、裸地、凍原 4 クラス、雪氷の 24 個である。このデータセットの全体精度は 59.4% である。

第3章 異分解能衛星画像を統合した土地被覆分類手法の提案

本章では、本研究の提案手法を説明する。1節で提案手法の概要を示す。提案手法はセグメンテーションとクラス分類の2段階に大別でき、より具体的なセグメンテーション手法を2節、クラス分類を3節で説明する。本研究での実装はPythonで行っており、実装コードは付録に記す。

3.1 概要

土地被覆分類において、中分解能衛星画像を用いた際にはピクセルベース、高分解能衛星画像を用いた際にはオブジェクトベースの土地被覆分類手法を用いることで高い精度が実現されており、衛星画像の分解能によって最適な土地被覆分類手法が異なる。これは、高分解能衛星画像では、自動車や標識などの土地被覆には関係のない地物の影響が無視できなくなり、従来のピクセルベースの土地被覆分類手法を用いると、詳細な地物がノイズとなり誤分類を多く引き起こしてしまうことに起因する。そのため、中分解能衛星画像と高分解能衛星画像を1つのモデルに組み込む際、どのようにこれらの手法を融合させるかがポイントとなると考えられる。

本研究における手法を以下に示す(図 3-1)。本研究の提案手法は、オブジェクトベースの土地被覆分類手法を踏襲し、従来のピクセルベースの土地被覆分類手法を拡張したものと位置付けられる。本研究の手法では、入力画像として中分解能衛星画像と高分解能衛星画像を用いる。その際、中分解能衛星画像にはクラス分類を行う対象地点を中心としたパッチを作成し、パッチのスペクトル値を入力とした伊東らによって提案されたピクセルベースの分類手法を適用する[伊東ら 2016]。一方で、高分解能衛星画像には中分解能衛星画像と同様にパッチを作成した上でのピクセルベースの分類を行うが、分類の際の入力としてスペクトル値に加え、オブジェクト特徴量を与えることで、高分解能衛星画像を用いた際のピクセルベースの土地被覆分類手法の問題点を補う。オブジェクト特徴量は、一般的なオブジェクトベースの土地被覆分類手法と同様にクラス分類の前にセグメンテーション処理を行い、セグメンテーション処理で得られた各オブジェクトの特徴量をオブジェクトが属する各ピクセルに付与する。そして、そのピクセルのスペクトル値と付与した特徴量を入力としてピクセルベースの分類を行う。

また、異分解能衛星画像を1つのモデルに組み込む際、分解能の違いにより、パッチサイズが異なることが懸念される。例えばクラス分類を行う領域が10m四方で、パッチサイズを1片30mの大きさになるよう入力を調整するとする。このときに用いる衛星画像の分解能が1mと10mであったとすると、分解能1mの衛星画像が構成するパッチは一辺

30 ピクセルなのに対し、分解能 10 m の衛星画像が構成数するパッチは一辺 3 ピクセルであり、クラス分類に利用するパッチのサイズが異なる。そのため、異なる大きさの入力に対応したクラス分類手法を考える必要がある。本研究ではこの問題に対応するため、ニューラルネットワーク分野において提案されている SPP-Net と呼ばれる手法を用いる [He et al. 2014]。SPP-Net は、通常の畳み込みニューラルネットワークの畳み込み層と全結合層の間に SPP 層を挟むことで、異なるサイズの入力に対しても高い精度でクラス分類を行うことが出来る。

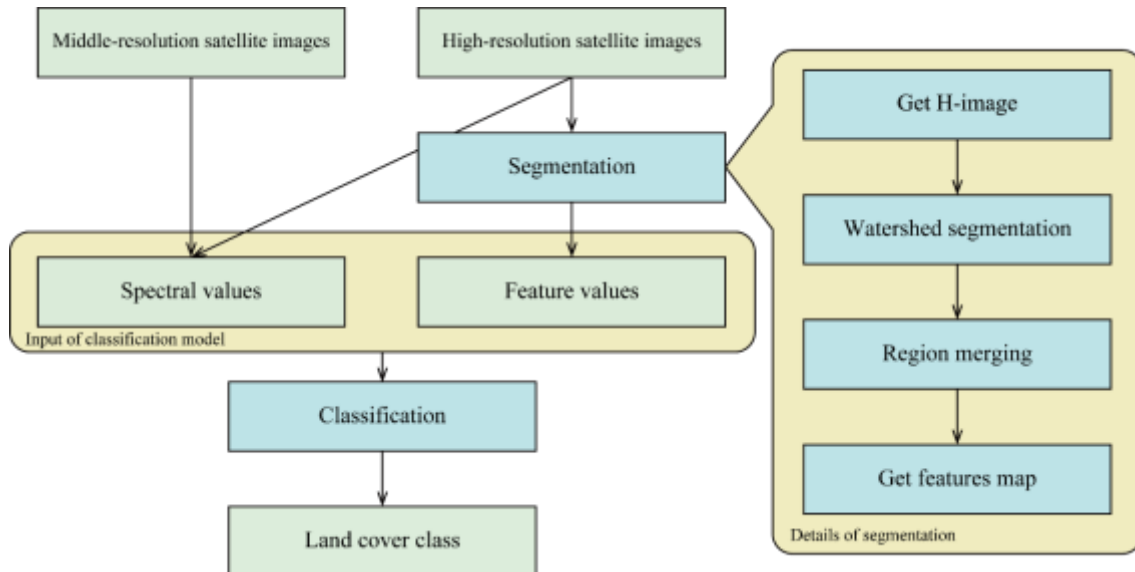


図 3-1 提案手法の概要

3.2 セグメンテーション

本研究では、高分解能衛星画像においては、オブジェクト特徴量を取得し、特徴量マップを作成するためセグメンテーションを行う。セグメンテーションは Chen らが提案している watershed 変換に基づいた手法を採用した [Chen et al. 2008]。この手法は以下の手順でセグメンテーションが行われる (図 3-2)。

1. 入力画像を基に微分画像 (H 画像) を生成する [Jing et al. 2003]。
2. H 画像を基に watershed 変換を行い、セグメンテーションを行う。 [Vincent et al. 1991, Beucher 1992, De Smet et al. 2000]。この際、over-segmentation と呼ばれる過剰にセグメンテーションが行われ、1 つ 1 つのオブジェクトが小さくなりすぎる問題点に留意する。
3. 上記の問題を解消するため、RAG (Region adjacency graph) を用いた領域の統合を行い、類似性の高いオブジェクトの統合を行う [Saarinen 1994]。
4. 各オブジェクトから特徴量を取得し、特徴量マップを作成する。




図 3-2 セグメンテーションのフローチャート

3.2.1 H 画像の作成

Jing らによって H 画像と呼ばれるグレイスケールの同質性勾配画像が提案されている [Jing et al. 2003]. H 画像の各ピクセルの値は H 値と呼ばれ, これはそのピクセルを中心としたローカルウィンドウの値によって計算される. H 画像の各ピクセルの値はオブジェクトの境界らしさを表す.

H 画像の計算は具体的に以下のように行われる. まず, 入力画像を用意する. ちなみに, H 画像の計算に入力画像はチャンネルに制限はない. 画像の左上を原点として (x, y) 座標を取り, 各座標の輝度値を $I(x, y)$ とする. また, P を同質性の計算を行うローカルウィンドウとする. いま, 一辺 $2N + 1$ のローカルウィンドウ P を考える. ここで, ピクセル c を P の中心のピクセルとしてその座標を (x_c, y_c) とする. この時, ピクセル c の輝度値は $I(x_c, y_c)$ となる. この際, 画像端を中心とする場合などローカルウィンドウが元の画像の領域外になる場合は, 画像端を鏡面軸として画像を補完する. また, ローカルウィンドウ P の各ピクセルを P_i とし, その座標を (x_i, y_i) とし, i の範囲を $[1: (2N + 1)^2]$ とする. ここで, ピクセル c からピクセル P_i へのベクトル cP_i を以下のように定義する.

$$cP_i = (x_i - x_c, y_i - y_c) \quad (3-1)$$

また, cP_i を基にベクトル f_i を定義する.

$$f_i = (I(x_i, y_i) - I(x_c, y_c)) \cdot \frac{cP_i}{\|cP_i\|} \quad (3-2)$$

すべての i に対し f_i を計算し, その総和をとったベクトル f を以下の通りとする.

$$f = \sum_{i=1}^{(2N+1)^2} f_i \quad (3-3)$$

それぞれのピクセルの H 値は f のノルムで与えられる.

$$H = \|f\| \quad (3-4)$$

入力画像がマルチチャンネルの場合は、 H 値は各バンドの H 値から以下のように計算される。

$$H_{\text{sum}} = \sqrt{\sum_{i=1}^N H_i^2} \quad (3-5)$$

3.2.2 watershed 変換

watershed アルゴリズムにおいて、多くの場合に入力画像として微分画像が用いられ、入力画像は地形的表面として考える。各ピクセルのスペクトル値は標高に対応し、高いスペクトル値は高地を低いスペクトル値は低地と考える（図 3-3）。




図 3-3 watershed アルゴリズムの概念図[Vincent et al. 1991]

watershed 変換とは、入力画像から稜線を抽出する手法である。まず、入力画像から局所的な低地を探索する (minima)。その後、それぞれの minima に対して水を注入し、異なる minima に注いだ水が干渉する線を境界とし、minima を中心として囲む境界が 1 つの領域となる。すなわち、入力画像は watershed 変換によって最初に探索した minima の数に領域が分割される。minima の探索は、すべてのピクセルにおいて、対象ピクセルの周囲 8 方向のピクセルにおいてスペクトル値を比較して周囲 8 方向のどのピクセルよりも対象ピクセルのスペクトル値が小さかった場合にそのピクセルを minima とする、処理を行った。

しかし、watershed 変換によってセグメンテーションを行った場合、画像を過度に分割してしまうこと (over-segmentation) が報告されているため、一般的にはセグメンテーション処理後に領域統合処理を行う。

3.2.3 領域統合

過剰に分割したオブジェクトを統合する際には、各オブジェクトのテクスチャ、色、形などを基に統合するオブジェクトを選択する。オブジェクトのデータ構造は領域近傍グラフ (RAG) を用いて表現する。RAG は画像内のセグメント化した領域をノードとして、隣接する領域間をエッジで連結することでグラフを構成する。各エッジには領域と領域を統合する際のコスト D をエッジのプロパティとして保持させる。領域統合は以下の手順で行われる（図 3-4）。

1. オブジェクト情報からノードとエッジを取得しグラフを作成する.
2. 各エッジの統合コスト D を計算する.
3. 統合コスト D の最小値とそのエッジを取得する
4. 領域面積の平均値 (SP 値) が閾値以上であれば統合処理を終了し, 閾値未満であれば処理を続ける.
5. 統合コスト D が最小となるエッジで結ばれた領域 (ノード) を統合する
6. ノード情報, エッジ情報, 統合コストを再計算し, 3 に戻る.

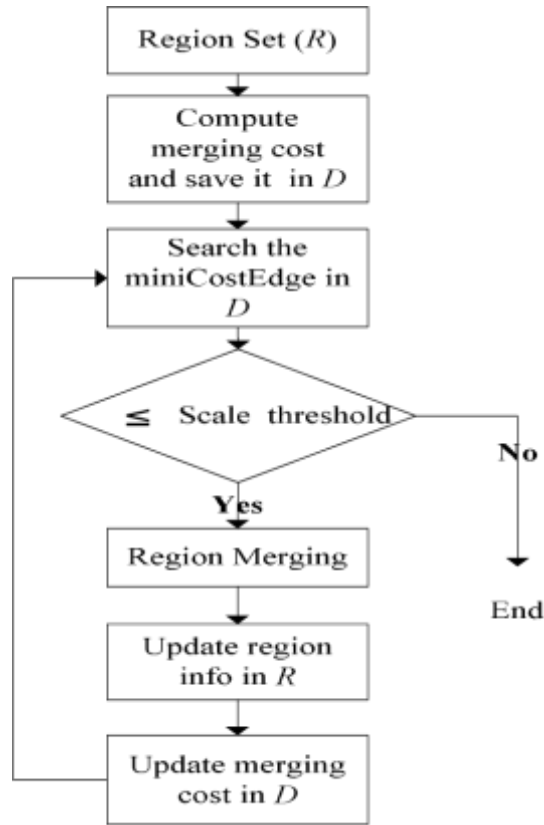


図 3-4 統合処理のフローチャート [Chen et al. 2008]

また, 統合コスト D は以下の式で計算される.

$$\begin{aligned}
 D &= w_{\text{color}} \cdot h_c + w_{\text{shape}} \cdot h_s \\
 w_{\text{color}} &\in [0, 1], w_{\text{shape}} \in [0, 1], w_{\text{color}} + w_{\text{shape}} = 1 \\
 h_c &= \sum_c w_c \left(n_m \cdot \sigma_{c,m} - (n_{\text{obj}1} \cdot \sigma_{c,\text{obj}1} + n_{\text{obj}2} \cdot \sigma_{c,\text{obj}2}) \right) \\
 h_s &= w_{\text{cm}} \cdot h_{\text{cm}} + w_{\text{sm}} \cdot h_{\text{sm}} \\
 h_{\text{cm}} &= n_m \cdot \frac{l_m}{\sqrt{n_m}} - \left(n_{\text{obj}1} \cdot \frac{l_{\text{obj}1}}{\sqrt{n_{\text{obj}1}}} + n_{\text{obj}2} \cdot \frac{l_{\text{obj}2}}{\sqrt{n_{\text{obj}2}}} \right) \\
 h_{\text{sm}} &= n_m \cdot \frac{l_m}{b_m} - \left(n_{\text{obj}1} \cdot \frac{l_{\text{obj}1}}{b_{\text{obj}1}} + n_{\text{obj}2} \cdot \frac{l_{\text{obj}2}}{b_{\text{obj}2}} \right)
 \end{aligned} \tag{3-6}$$

この際、 w_{color} 、 w_{shape} 、 w_c 、 w_{cm} 、 w_{sm} は重みパラメータであり、 l_{obj} は領域の周囲長、 b_{obj} は領域のバウンディングボックスの周囲長、 n_{obj} は領域のサイズ、 $\sigma_{c,obj}$ は領域のチャンネル c のスペクトル値の標準偏差である。

領域統合過程における重みパラメータの決定には、比較的セグメンテーション結果への影響が少ない w_c 、 w_{cm} 、 w_{sm} に関しては、 $w_c = 1.0$ 、 $w_{cm} = 0.5$ 、 $w_{sm} = 0.5$ と多くの研究で用いられている値を与え、 w_{color} 、 w_{shape} はBorsottiらの手法を用いて最適なパラメータを決定した[Borsotti et al. 1998]。これは、下式の評価関数を定義し、この式の値が小さいほど、よいセグメンテーション結果が得られると判断する。

$$Q = \frac{1}{10000(N \times M)} \sqrt{R} \times \sum_{i=1}^R \left[\frac{e_i^2}{1 + \log A_i} + \left(\frac{R(A_i)}{A_i} \right)^2 \right] \quad (3-7)$$

上式において、 Q はセグメンテーション結果の評価値、 N は入力画像の縦幅、 M は入力画像の横幅、 R はセグメンテーションされた画像内に存在するオブジェクト数、 A_i は i 番目のオブジェクトの面積、 e_i は i 番目のオブジェクトのスペクトル誤差、 $R(A_i)$ は A_i と同じ面積を持つオブジェクトの数を表す。

また、統合処理は、大きなサイズの画像に対して行うと、一度の統合に伴う計算処理が非常に大きくなるため、事前に分割した画像に対して統合処理を行った。この際、画像の分割を細かくすると統合処理に影響を与えてしまうことが懸念される。今回は、統合処理に十分影響を与えない大きさとして分割後の画像の一边は500ピクセルとした。

3.2.4 オブジェクト特徴量の取得

入力画像をセグメンテーション処理によってオブジェクトに分割した後に、各オブジェクトから特徴量を取得した。本研究では、オブジェクトの特徴量としてオブジェクトの特徴をよく表現する以下の9項目を使用した。

- オブジェクトの面積（ピクセル数）
- オブジェクトのスペクトル値の平均（3バンド）
- オブジェクトのスペクトル値の分散（3バンド）
- オブジェクトの周囲長
- オブジェクトのバウンディングボックス周囲長

本研究では、セグメンテーション処理で得られた各オブジェクトの特徴量は、そのオブジェクトが属するピクセルの場所が得られた特徴量の値となる画像を作成し、特徴量マップとして入力画像のチャンネルに追加する（図 3-5）。

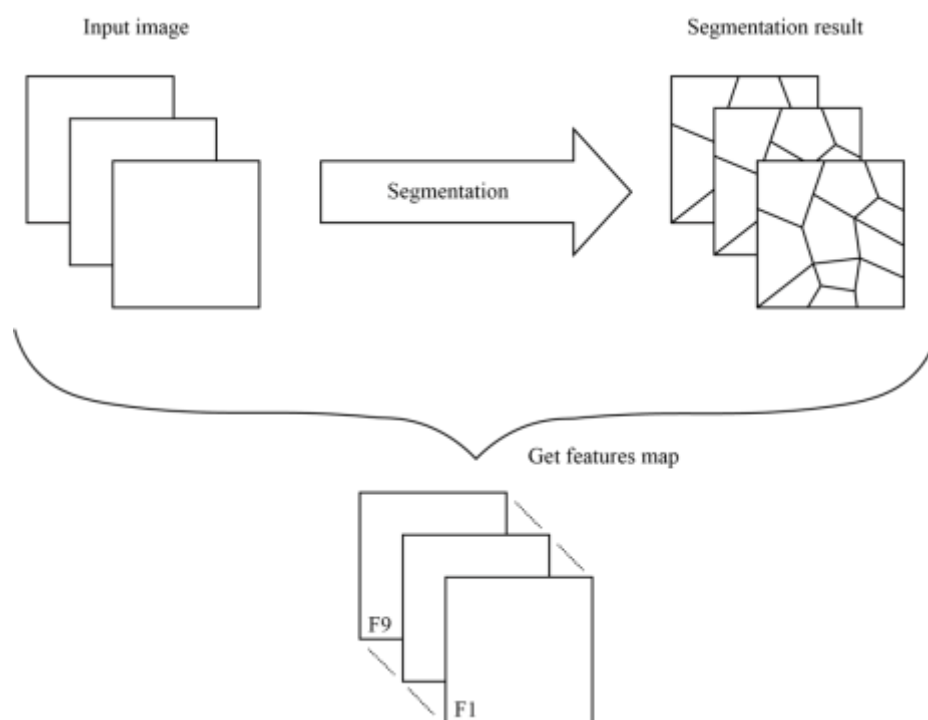


図 3-5 オブジェクト特徴量マップの取得

3.3 クラス分類

土地被覆分類を行うためには、入力画像（入力ピクセル）が指定したクラス一覧のどれに分類されるか判断する必要がある。本研究では、利用するデータセットとの兼ね合いを考え、クラス分類における対象領域を一辺 10 m の矩形領域とした。すなわち、クラス分類の入力として、土地被覆分類を行いたい一辺 10 m の矩形領域のスペクトル値を与え、出力として土地被覆クラスが得られる。この際、高分解能衛星画像に関しては、前段階でセグメンテーションにより取得したオブジェクト特徴量が入力値として加えられる。

異なる分解能を持つ衛星画像を入力画像としてクラス分類を行う際、実空間上においての面積と画像上のピクセル数の関係性について考慮する必要がある。同一の空間を表現する際、画像の分解能の違いによって対象地域を表現するピクセル数が異なる。例えば、一辺 10 m の矩形領域を表現する画像上のピクセル数は、分解能 30 m の Landsat では 1×1 ピクセル内に収まるが、分解能 0.31 m の WorldView-3 では 34×34 ピクセル程となる。そのため、同一の対象領域をクラス分類することを考えた時、分解能の違いによって入力ベクトルのサイズが異なる。

以上より、本研究では畳み込みニューラルネットワーク（CNN）を拡張した SPP-net をクラス分類器として利用する。SPP-net は 1 つのモデル内に多様なサイズの画像を入力とすることができ、本研究の手法として適切であると考えた。

本研究におけるクラス分類手法の概要図を以下に示す（図 3-6）。

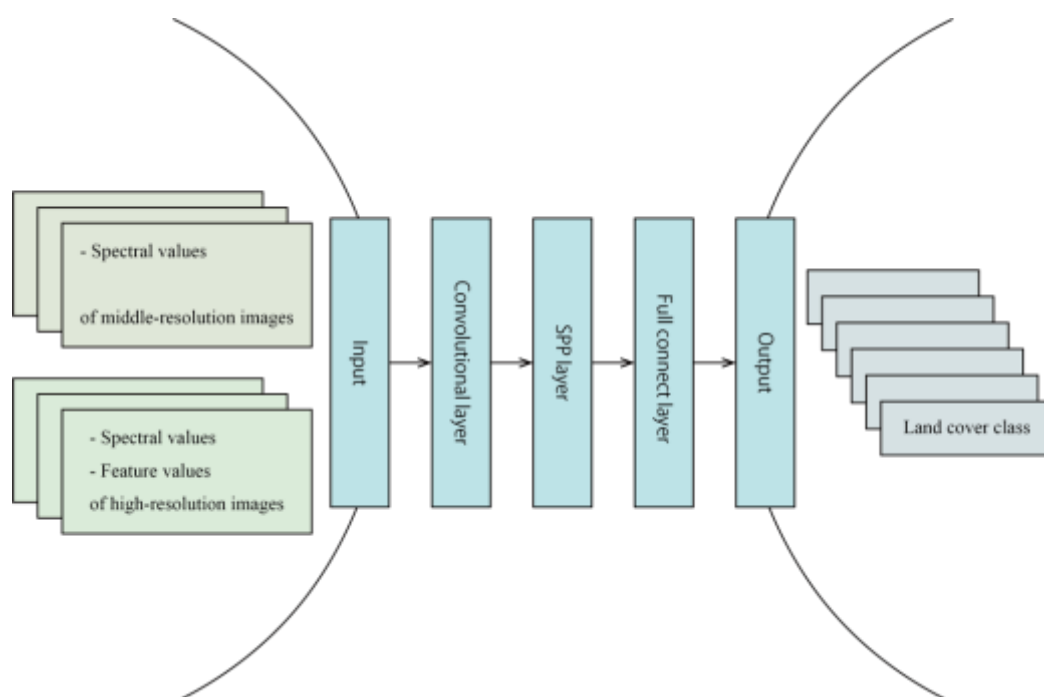


図 3-6 SPP-net を用いた異分解能衛星画像のクラス分類

本節では、はじめに一般的な畳み込みニューラルネットワークを説明し、その後に SPP-net について説明する。

3.3.1 畳み込みニューラルネットワーク

畳み込みニューラルネットワーク (CNN, Convolutional Neural Network) (図 3-7) は、画像の扱いに特化したニューラルネットワークであり、画像認識分野において近年高い分類精度を達成し注目されている手法の 1 つである[岡谷 2015]。CNN は生物の脳の視覚野における神経細胞の受容野の局所性と単純型細胞および複雑型細胞の存在をヒントにデザインされたニューラルネットワークである。CNN は入力側から出力側に向けて、畳み込み層とプーリング層という 2 種類の層がペアで並び、これが複数回繰り返される。畳み込み層とプーリング層ののちに、局所コントラスト正規化層を挿入する場合もある。畳み込み層とプーリング層の繰り返しの後には、隣接層間のユニットが全結合した全結合層が配置される。全結合層を複数連続して配置し、最後に出力層であるソフトマックス層を配置する。




図 3-7 画像認識などで一般的に用いられる CNN の構造[岡谷 2015]

畳み込み層について説明する．その前にまず画像の畳み込みとは何か説明する．ここで，入力画像（サイズ $W \times W$ ，簡単のためにグレイスケールで考える．）とフィルタ（サイズ $H \times H$ ）を考える．画像の畳み込みは，画像とフィルタ間で定義される積和計算を表す．入力画像の点 (i, j) における画素値を $x(i, j)$ ，フィルタの点 (p, q) における画素値を $h(p, q)$ とした時，畳み込みの計算は以下のように定義される．

$$u_{ij} = \sum_{p=0}^{H-1} \sum_{q=0}^{H-1} x_{i+p, j+q} h_{pq} \quad (3-8)$$

フィルタの濃淡パターンと類似した濃淡パターンが入力画像のどこにあるかを検出する働きがある．すなわち，フィルタが表す特徴的な濃淡構造を画像から抽出することができる．畳み込み層は，上述した畳み込みの演算を行う単層ネットワークである．上述では，簡単のためグレイスケール画像に対して1つのフィルタを適用した際の説明をしたが，実用上では多チャンネルの画像に対し，複数のフィルタを並行して畳み込む演算を行う．

プーリング層は，通常畳み込み層の直後に設置され，畳み込み層で抽出された特徴の位置感度を若干低下させる．これにより，対象となる特徴量の画像内での位置が若干変化した場合でもプーリング層の出力が不変となり，対象のズレに頑健な識別が可能となる．プーリング層での計算は，次のように行われる．サイズ $W \times W \times K$ の入力画像で画素 (i, j) を中心とする $H \times H$ 正方領域を取り，この中に含まれる画素の集合を P_{ij} で表す．この P_{ij} 内の画素について，チャンネル k ごとに独立に， H^2 個の画素値を基に値を取得する．この際，最大値を取得するものを最大プーリング，平均値を取得するものを平均プーリングと呼ぶ．

畳み込み層とプーリング層の繰り返しの後には全結合層が配置されるが，これにより，CNN への入力画像は固定されたサイズである必要があった．この制約を取り除く方法が次節で説明する SPP-net である．

3.3.2 SPP-net

SPP-net (Spatial Pyramid Pooling network) とは，SPP 層と呼ばれる新しいタイプのプーリング層を導入した CNN である[He et al.2014]．従来の CNN には全結合層の入力サイズが固定であることに起因して，ニューラルネットワークへの入力画像の入力サイズは一定である必要があった．そのため，異なるサイズの入力画像を同一のニューラルネットワークに入力する場合は，ニューラルネットワークへ入力する前に入力画像に対して切り出しやリサイズなどの画像変換を行い入力画像のサイズを揃えていた．しかしながら，入力画像の切り出しは対象オブジェクトの全てを画像内に含めることができないかもしれないし，入力画像のリサイズは予期せぬ画像の歪みが生じるかもしれないといった問題点がある（図 3-8）．そのため，様々な画像サイズを対象とした CNN によるクラス分類は，これまで高精度を達成できていなかった．



図 3-8 画像の切り出し前後と画像のリサイズ前後

これを克服したのが He らの提案した SPP-net である。He らは、CNN における入力画像の大きさが固定であることは全結合層の入力サイズが固定であることに起因しており、それ以外の畳み込み層等ではそのような制限がないことに着目した。従来は CNN 入力前に入力画像の画像変換を行うことで入力サイズを揃えていたが、SPP-net では入力画像のサイズに制限を設けず全結合の直前で SPP 層を用いて固定サイズに変換する（図 3-9）。



図 3-9 従来の CNN を用いた画像分類（上）と SPP-net を用いた画像分類（下）

それでは、SPP 層は具体的にどのような働きを持つ層なのか説明する。SPP 層の概念図を以下に示す（図 3-10）。SPP 層は、日本語で訳すと空間的階層プーリング層であり、ニューラルネットワークにおける従来のプーリング層の派生である。SPP 層はプーリング層をいくつかの階層に分け、それぞれの階層でプーリングを行う（He らの研究では最大プーリングが用いられている）。そしてそれぞれの階層で得られたプーリングの出力を連結することで SPP 層の出力とする。下図では、階層を 3 つ設けており、それぞれの階層のベクトルのサイズは 16, 4, 1 で合計 21 となる。SPP 層の出力はそれぞれの階層のベクトルのサイズの和と入力チャンネル数の積となる。

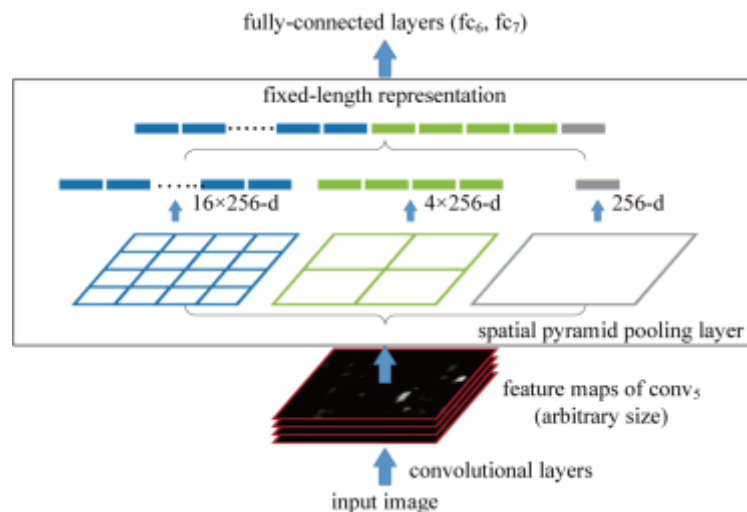


図 3-10 SPP 層の概略図[He et al.2014]

このように、入力画像の切り出しやリサイズを行わずに、ニューラルネットワークに入力して、ニューラルネットワーク内部においてプーリングを行うことで、入力画像の特徴量を極端に落とすことを防ぐことができる。

第4章 提案手法の検証

本章では，提案手法の検証により得られた結果を記す．まず，検証に用いるデータセットおよび検証条件を説明し，続いて検証結果を紹介し，本検証から得られた示唆を記す．

4.1 検証に用いたデータ

本検証を行うにあたり，異なる分解能を持つ複数の衛星画像と既に得られている土地被覆分類図を利用した．具体的には，以下に記した3種類のデータを用いた．

- Terra 衛星による中分解能衛星画像
- WorldView-3 衛星による高分解能衛星画像
- JAXA が公開している高解像度土地利用被覆図

撮影場所は，取得できる衛星画像の中で，比較的 land cover が混在している秋田県鹿角市を選択した．秋田県鹿角市は，水田，畑地，森林が land cover の多くを占めている．以後，これらのデータについて順を追って詳細に説明する．これらを用いて作成したデータセットに関しては，検証ごとに説明する．

4.1.1 Terra 衛星画像

中分解能衛星画像として，Terra 衛星の光学センサー ASTER (Advanced Spaceborne Thermal Emission and Reflection Radiometer, 高性能熱放射反射放射計) により撮影された衛星画像を用いた．Terra 衛星は 1992 年に打ち上げられ，軌道高度 705km の太陽同期軌道を描き，回帰日数は 16 日である．Terra に搭載されている ASTER は VNIR (可視近赤外放射計)，SWIR (短波長赤外放射計)，TIR (熱赤外放射計) の 3 つのセンサーで構成されている．以下に ASTER の詳細なスペックシートを示す (表 4-1)．

表 4-1 Terra に搭載されている光学センサー ASTER

| | VNIR | SWIR | TIR |
|------------|---------|-----------|-------------|
| バンド数 | 3 | 6 | 5 |
| 波長 [nm] | 520~600 | 1600~1700 | 8125~8475 |
| | 630~690 | 2145~2185 | 8475~8825 |
| | 760~860 | 2185~2225 | 8925~9275 |
| | | 2235~2285 | 10250~10950 |
| | | 2295~2365 | 10950~11650 |
| | | 2360~2430 | |
| 分解能 [m] | 15 | 30 | 90 |
| 観測幅 [km] | 60 | 60 | 60 |
| ビット数 [bit] | 8 | 8 | 12 |

ASTER は異なる波長を検出する 3 つのセンサーによって構成されているが、本研究では土地被覆分類によく用いられる可視から近赤外波長域の地表の太陽反射光を検出する VNIR から得られたデータを用いた。ASTER によって撮影された画像は、国立研究開発法人産業技術総合研究所地質調査総合センターが全てウェブ上に公開しており、本研究で用いる画像はこのサイトを通じて選択・ダウンロードしたものである[GSJ 2016]。後に説明する高分解能衛星画像の方が画像の選択の幅が限られていたため、高分解能衛星画像の撮影場所を含み、撮影時期が近く、被雲率が小さい画像を選択した。選択した画像の撮影条件と画像を以下に示す（表 4-2, 図 4-1）。

表 4-2 本研究で用いた画像の撮影条件（Terra により撮影）

| | |
|--------------------|-----------------------|
| Date | 2015/10/01 |
| Latitude | 39.70273~40.356736 |
| Longitude | 140.588911~141.475668 |
| Image size (pixel) | 5064×4854 |




図 4-1 本研究で用いた画像（Terra により撮影）

また、本研究では異なる分解能を持つ衛星画像の撮影領域を揃えるため、選択した画像を高分解能衛星画像に合わせて切り出しを行った。以下に切り出した画像の条件と画像を示す（表 4-3, 図 4-2）。本研究では切り出し後の画像を用いて検証を行った。

表 4-3 本研究で用いた画像の撮影条件（Terra により撮影）（切り出し後）

| | |
|--------------------|----------------------|
| Date | 2015/10/01 |
| Latitude | 40.2223~40.2444 |
| Longitude | 140.7787323~140.8078 |
| Image size (pixel) | 166×164 |




図 4-2 本研究で用いた画像（Terra により撮影）（切り出し後）

4.1.2 WorldView-3 衛星画像

高分解能衛星画像として、WorldView-3 衛星の光学センサーにより撮影された衛星画像を用いた。WorldView-3 衛星は 2014 年に打ち上げられ、軌道高度 617km の太陽同期準回帰軌道を描く。WorldView-3 に搭載されている光学センサーはパンクロマチック、8 バンドマルチスペクトル、8 バンド SWIR、1 2 バンド CAVIS で構成されている。以下に WorldView-3 に搭載されている光学センサーの詳細なスペックシートを示す（表 4-4）。

表 4-4 WorldView-3 に搭載されている光学センサー

| センサー | パナクロマチック | マルチスペクトル | SWIR | CAVIS |
|------------|----------|---|--|--|
| バンド数 | 1 | 8 | 8 | 12 |
| 波長 [nm] | 450~800 | 400~450 450~510 510~580 585~625 630~690 705~745 770~895 860~1040 | 1195~1225 1550~1225 1640~1590 1710~1680 2145~1750 2185~2185 2235~2225 2295~2285 | 405~420 459~509 525~585 635~685 845~885 897~927 930~965 1220~1252 1365~1405 1620~1680 2105~2245 2105~2245 |
| 分解能 [m] | 0.31 | 1.24 | 3.70 | 30.0 |
| 観測幅 [km] | 13.1 | 13.1 | 13.1 | - |
| ビット数 [bit] | 11 | 11 | 14 | - |

WorldView-3 は異なる波長を検出する 4 つのセンサーが搭載されているが、本研究では土地被覆分類によく用いられる可視から近赤外波長域の地表の太陽反射光を検出するマルチスペクトルセンサから得られたデータを用いた。WorldView-3 のマルチスペクトルセンサによって撮影された画像は、Digital Globe 社を通じて一般に販売がおこなわれており、本研究では比較的被雲率が小さい画像を選択した。選択した画像の撮影条件と画像を以下に示す（表 4-5、図 4-3）。

表 4-5 本研究で用いた画像の撮影条件（WorldView-3 により撮影）

| | |
|--------------------|----------------------|
| Date | 2014/11/12 |
| Latitude | 40.2223~40.2444 |
| Longitude | 140.7787323~140.8078 |
| Image size (pixel) | 8262×8177 |



図 4-3 本研究で用いた画像（WorldView-3 により撮影）

4.1.3 AVNIR-2 高解像度土地利用被覆図 ver. 16.02

AVNIR-2 高解像度土地利用被覆図 ver. 16.02 は、橋下らによって日本全域（一部の離島を除く）の土地被覆分類を推定したもので、植生調査や森林管理、土砂災害などの調査資料等の実利用分野や生態系研究等、様々なアプリケーションの基盤情報として活用することを目的としている[橋本ら 2014]。このデータセットは JAXA によって無料で公開されている。

このデータセットの作成には、「だいち」（ALOS）搭載の光学センサーである高性能可視近赤外放射計 2 型（AVNIR-2）の観測データを中心に以下のデータが用いられている。

1. ALOS AVNIR-2 HLP 2,791 シーン
2. ALOS PRISM 5m 解像度 Digital Surface Model (DSM)
3. ALOS PALSAR 25m 解像度 2008 年 モザイクデータセット
4. 国土地理院数値地形データ 10m 解像度と、そこから求めた傾斜のラスターマップ
5. Suomi NPP 夜間光データ 500m 解像度
6. オープンストリートマップによる道路網・水路網・鉄道網・建物ベクターデータ（© OpenStreetMap contributors）から求めた、道路からの距離のラスターマップ
7. 北海道市町村ごとの水稲作付けの有無情報（出典：農林水産省による「農林水産関係市町村別統計（平成 26 年産 水稲 北海道）」）
8. 教師情報 18,636 地点

これらのデータを以下の手法をそれぞれに用い、その結果を統合したベイズ推定と分類後編集により分類を行った。

- データ 1 とデータ 8 を用いた、カーネル密度による尤度推定
- データ 2 を用いた、ALOS AVNIR-2 観測時の地形性の日影の分布推定
- データ 3～データ 8 を用いた、カーネル密度による事前確率推定

作成された土地被覆のデータ形式および精度等は以下の表の通りである(表 4-6)。また、日本全域の土地被覆結果を以下に記す(図 4-4)。

表 4-6 土地被覆分類図のデータ形式

| | |
|----------|---|
| 座標系 | 緯度経度直交座標系 (GRS80 楕円体, ITRF94) |
| 格納単位 | 緯度経度 1 度単位のグリッドタイル。 (12000 × 12000 ピクセル) |
| メッシュサイズ | 1/12,000 度 × 1/12,000 度 (およそ 10m × 10m に相当) |
| 格納形式 | GeoTIFF 形式 |
| 対象期間 | 2006 年～2011 年。 但し、2011 年東日本大震災の影響は含めない。 |
| 土地被覆クラス数 | 10 |
| 土地被覆クラス | 1 : 水域, 2 : 都市, 3 : 水田, 4 : 畑地, 5 : 草地, 6 : 落葉広葉樹, 7 : 落葉針葉樹, 8 : 常緑広葉樹, 9 : 常緑針葉樹, 10 : 裸地 |
| 全体精度 | 0.78 |
| κ 係数 | 0.745 |




図 4-4 日本全国の土地被覆分類結果

本研究では，AVNIR-2 高解像度土地利用被覆図 ver. 16.02 を基に対象地域である秋田県鹿角市の土地被覆を取得した．対象地域の土地被覆分類図を以下に記す（図 4-5）．




図 4-5 対象地域の土地被覆分類結果

4.1.4 データセットの作成

前述の3種類のデータから、実際に検証に用いるデータセットを作成した。データセットは土地被覆分類を行う対象領域を中心とした一辺50ピクセルのパッチ画像とその地点の土地被覆クラスのペアの集合から成り立つ。本検証では、出力クラス数、データ水増しの有無、高分解能衛星画像におけるオブジェクト特徴量の有無を変化させて、合計9種類のデータセットを作成した。

作成したデータセット一覧を示す(表4-7)。表中の「衛星画像の分解能」はデータセットの作成に用いた衛星画像の分解能を示しており、中分解能はTerraの衛星画像、高分解能はWorldView-3の衛星画像によって作成されたことを示す。また、「クラス数」は土地被覆クラス数を示す。「水増し」はデータにノイズ等を加えて水増しを行ったかどうかを示す。「オブジェクト特徴量」は高分解能衛星画像において前処理のセグメンテーションにより取得したオブジェクト特徴量を利用したかどうかを示す。「データ数」は各データセットのデータ数を示す。「検証名」は対象のデータセットがどの検証で用いられたかを示す。

データセットのより詳細な説明は、各検証の節にて具体的に説明する。

表 4-7 作成したデータセット一覧

| データセット名 | 衛星画像の分解能 | クラス数 | 水増し | オブジェクト特徴量 | データ数 | 検証名 |
|-------------|----------|------|-----|-----------|-------|-----|
| Dataset-L1 | 中分解能 | 10 | × | × | 6806 | 検証Ⅰ |
| Dataset-H1 | 高分解能 | 10 | × | × | 26446 | |
| Dataset-H1F | 高分解能 | 10 | × | ○ | 26446 | |
| Dataset-L2 | 中分解能 | 7 | × | × | 6806 | 検証Ⅱ |
| Dataset-H2 | 高分解能 | 7 | × | × | 26446 | |
| Dataset-H2F | 高分解能 | 7 | × | ○ | 26446 | |
| Dataset-L3 | 中分解能 | 7 | ○ | × | 21502 | 検証Ⅲ |
| Dataset-H3 | 高分解能 | 7 | ○ | × | 80086 | |
| Dataset-H3F | 高分解能 | 7 | ○ | ○ | 80888 | |

4.2 検証に用いた SPP-net の構造

提案手法においてクラス分類に利用されるニューラルネットワークの構造は、フィルタサイズ3フィルタ数16の畳み込み層2層、全結合層2層のSPP-netとした。ネットワークの構造を示した図を以下に示す(図4-6)。

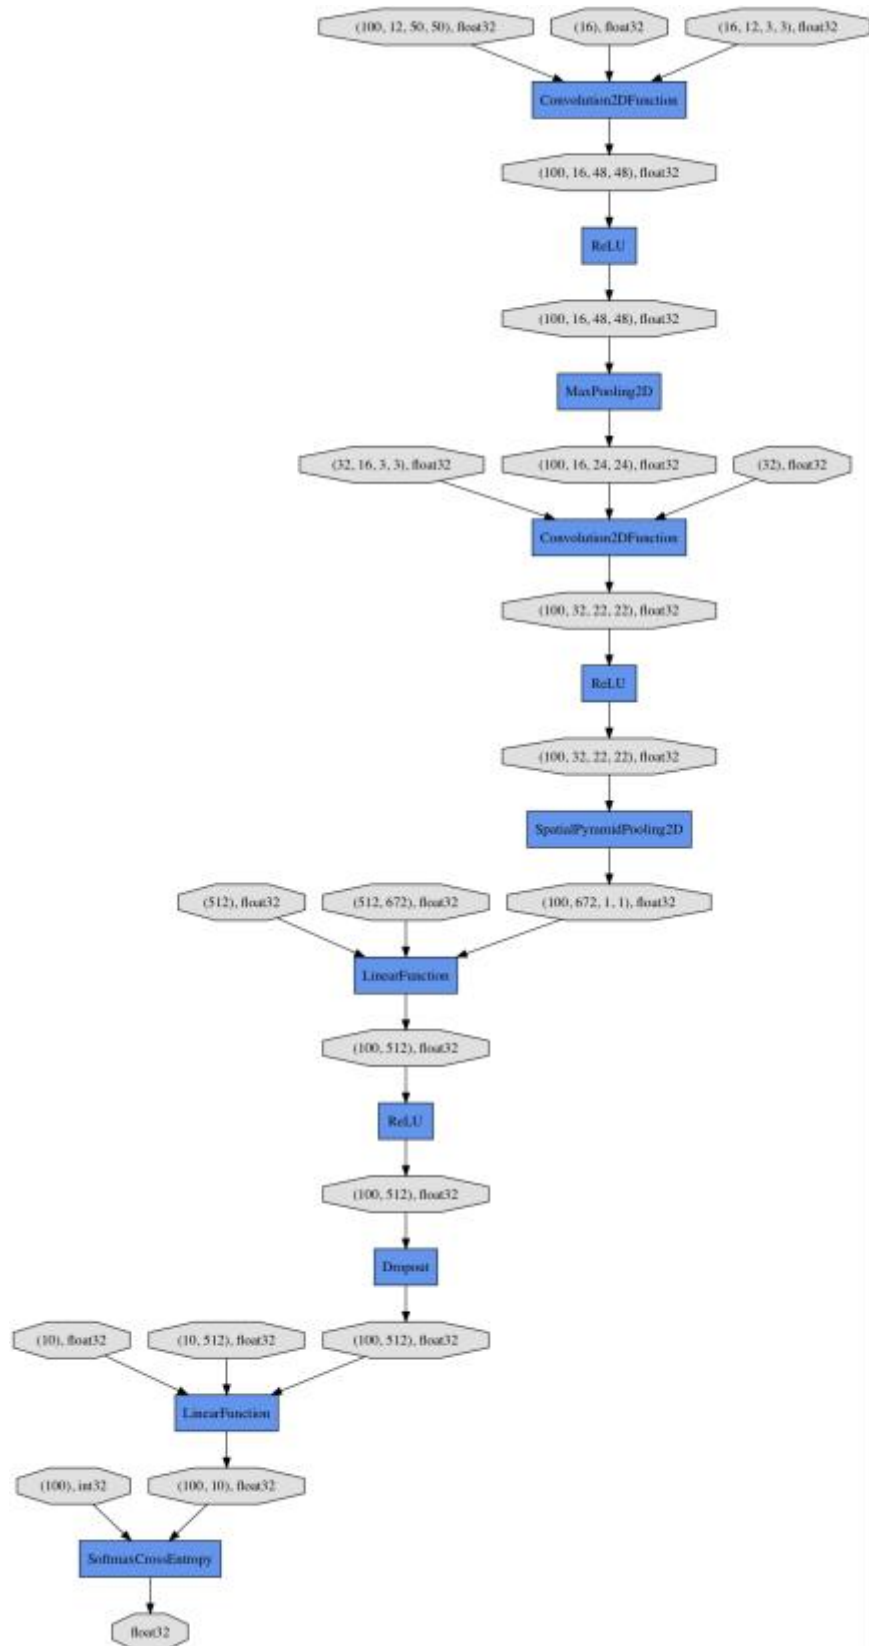


図 4-6 本検証で用いたネットワーク図

4.3 予備検証

本検証を行う前に、高分解能衛星画像のセグメンテーションにおける領域統合処理において用いるパラメータ w_{color} , w_{shape} を決定するための予備検証を行った。本検証では、様々な w_{color} , w_{shape} に対して、高分解能衛星画像における対象地域の一部を用いてセグメンテーション処理を行い、対象地域における最適な w_{color} , w_{shape} を決定することが目的である。

4.3.1 検証条件

本検証の対象領域の撮影条件と画像を以下に示す（表 4-8, 図 4-7）。

表 4-8 予備検証で用いた画像の撮影条件（WorldView-3 により撮影）

| | |
|--------------------|-------------------------------|
| Date | 2014/11/12 |
| Latitude | 40.2349405405~40.2362918919 |
| Longitude | 140.7822505401~140.7840096602 |
| Image size (pixel) | 500 × 500 |



図 4-7 予備検証で用いた画像（WorldView-3 により撮影）

続いて、本検証で行った条件を以下の表に示す（表 4-9）。それぞれの条件において、SP 値が 100 増加するごとにセグメンテーション結果を出力し、SP 値が 2500 になるまで統合処理を行った。

表 4-9 予備検証の条件

| # | 検証名 | Wcolor | Wshape |
|---|--------|--------|--------|
| 1 | wc=0.1 | 0.1 | 0.9 |
| 2 | wc=0.3 | 0.3 | 0.7 |
| 3 | wc=0.5 | 0.5 | 0.5 |
| 4 | wc=0.6 | 0.6 | 0.4 |
| 5 | wc=0.7 | 0.7 | 0.3 |
| 6 | wc=0.8 | 0.8 | 0.2 |
| 7 | wc=0.9 | 0.9 | 0.1 |

4.3.2 検証結果

本検証で領域統合の前段階で得られた、H 画像と watershed 変換によるセグメンテーション結果（領域統合処理前）を以下に示す（図 4-8, 図 4-9）. 図 4-9 では背景に元の画像を配置し，前面にはセグメンテーションされた画像のオブジェクトごとに異なる色が割り当てられた画像を重ねて表示している．




図 4-8 対象領域の H 画像




図 4-9 対象領域の watershed 変換によるセグメンテーション結果

また、縦軸を Borsotti らが提案した[Borsotti et al. 1998]評価値（以下 Borsotti 値とする）、横軸を SP 値としたグラフ（図 4-10）と縦軸を Borsotti 値、横軸を w_{color} としたグラフ（図 4-11）を以下に示す。Borsotti 値は小さいほどよいセグメンテーション結果が得られていると判断される。

図 4-10 より、 w_{color} に関係なく、SP 値が増加に伴い Borsotti 値は増加することがわかる。これは、SP 値の増加に伴い各オブジェクトの面積は増加し、スペクトル誤差の影響が大きくなることに起因すると考えられる。また、図 4-11 より、どの SP 値においても概ね、 w_{color} の増加に伴い、Borsotti 値は減少し、 $w_{\text{color}} = 0.8$ で最小となり、 w_{color} をさらに増加させると、Borsotti 値は増加しているに見える。以上の結果より、本研究では、 $w_{\text{color}} = 0.8$ 、 $w_{\text{shape}} = 0.2$ として統合処理を行った。

ここで、 $w_{\text{color}} = 0.8$ 、 $w_{\text{shape}} = 0.2$ で統合処理を行った際の結果を SP 値ごとに示す（図 4-12）。SP 値の増加に伴い、各オブジェクトは大きくなるが、異なる土地被覆を 1 つのオブジェクトとして認識しているケースも見られた。セグメンテーションの段階で異なる土地被覆を 1 つのオブジェクトとみなしてしまうと、後のクラス分類では精度が低下する。そのため、オブジェクトの統合処理は最低限でよいと判断し、本研究では SP=100 の領域統合処理結果を用いた。




図 4-10 様々な w_{color} における SP 値と Borsotti 値の関係




図 4-11 様々な SP 値における w_{color} と Borsotti 値の関係




図 4-12 領域統合結果 ($w_{color}=0.8$, $w_{shape}=0.2$)

4.4 検証 I

検証 I では、出力クラスを準備された土地被覆分類図で利用されていた土地被覆クラスをそのまま利用して、データセットを作成して、土地被覆分類の精度検証を行った。

4.4.1 データセット

本検証で用いたデータセットの一覧を以下に示す（表 4-10）。続けて、用いたデータセットの詳細を記す。

表 4-10 検証 I で用いたデータセット

| データセット名 | 衛星画像 | クラス数 | 水増し | オブジェクト特徴量 | データ数 |
|--------------------|------|------|-----|-----------|-------|
| Dataset-L1 | 中分解能 | 10 | × | × | 6806 |
| Dataset-H1 | 高分解能 | 10 | × | × | 26446 |
| Dataset-H1F | 高分解能 | 10 | × | ○ | 26446 |

Dataset-L1

パッチ画像は衛星画像から 2 ピクセル間隔で取得した一辺 1 ピクセルの画像を用いた。土地被覆クラスは取得したパッチの中心の緯度・経度を計算し、土地被覆図から対応する土地被覆クラスを取得した。一辺 1 ピクセルのパッチでは、後のクラス分類を行う CNN のフィルタより小さい入力サイズとなってしまうため、今回は一辺を 50 倍に拡大している。このデータセットでは、12 チャンネルのうちスペクトルで 3 チャンネルを利用し、残りの 9 チャンネルはオブジェクト特徴量を利用しないため 0 埋めした。

Dataset-H1

パッチ画像は衛星画像から 50 ピクセル間隔で取得した一辺 50 ピクセルの画像を用いた。土地被覆クラスは取得したパッチの中心の緯度・経度を計算し、土地被覆図から対応する土地被覆クラスを取得した。このデータセットではセグメンテーションにより得られたオブジェクト特徴量は使用していない。そのため、12 チャンネルのうちスペクトルで 3 チャンネルを利用し、残りの 9 チャンネルはオブジェクト特徴量を利用しないため 0 埋めした。

Dataset-H1F

Dataset-H1 にセグメンテーションにより得られたオブジェクト特徴量を付与したものである。

4.4.2 検証条件

検証条件を以下の表に示す(表 4-11). データセット項における「+」は, 複数のデータセットを混合して検証したことを意味する.

表 4-11 検証 I の検証条件

| 検証名 | データセット |
|-------|------------------------|
| exp_1 | dataset-H1F |
| exp_2 | dataset-H1F+dataset-L1 |
| exp_3 | dataset-H1 |
| exp_4 | dataset-H1+dataset-L1 |

4.4.3 検証結果

出力クラス 10, データ水増し無しのデータセット dataset-H1, dataset-H1F, dataset-L1 の 3 種類を用いた検証結果 (exp_1, exp_2, exp_3, exp_4) を示す.

SPP-net を用いた各検証条件の学習回数 (epoch 数) と訓練時とテスト時における分類精度 (Accuracy) と誤差値 (Loss) の関係性を示す (図 4-13). 続けて, SPP-net を用いた各検証条件の学習回数とテスト時におけるクラス分類精度の関係性を示す (図 4-14). 続けて, epoch=30 のモデルを用いた際の各検証条件のテストデータの分類結果を示す (図 4-15).

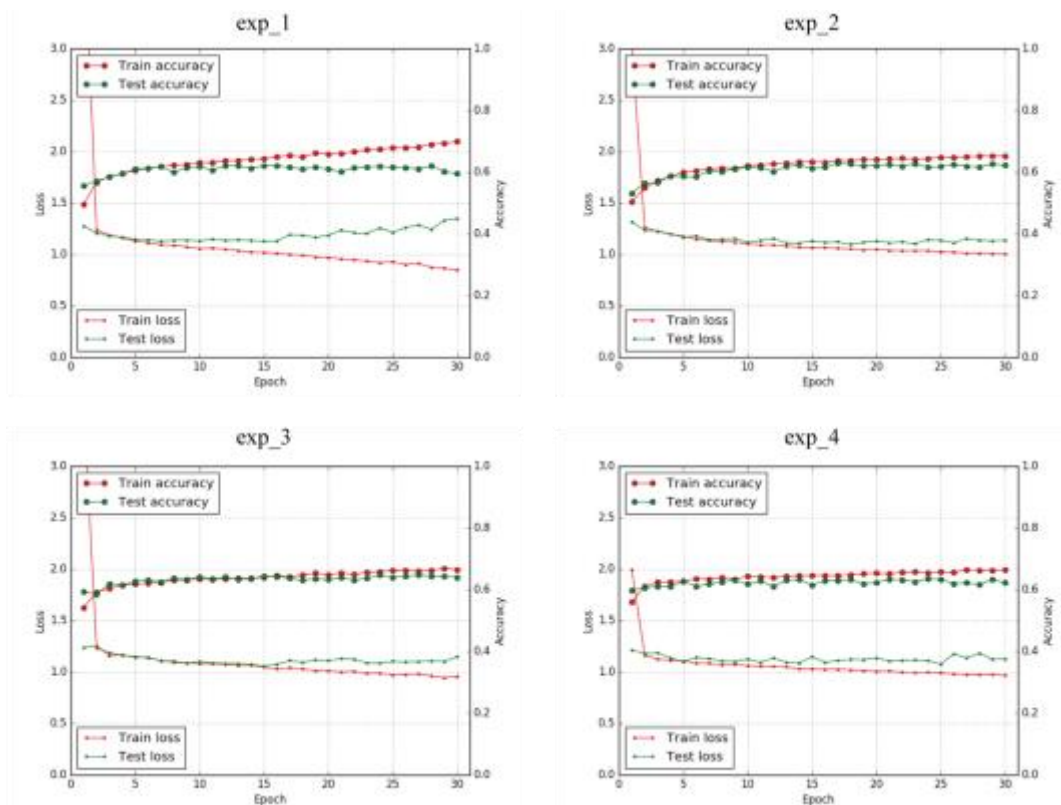


図 4-13 exp_1~exp_4 における学習経過




図 4-14 exp_1~exp_4 のクラス分類精度

| | | | | | | | | | | | | | | | | | | | | | |
|-----------|-----|------------|-------|---------------|------|------------|-----------|-------------------|-----|------------|----------|--------|--------|--------|--|------|--|--------|--|--------|--|
| Name | | exp_1 | | Over Accuracy | | 0.5999 | | Kappa Coefficient | | 0.3952 | | | | | | | | | | | |
| Reference | | water | urban | rice paddy | crop | grass | Precision | DNF | ERF | ENF | barmland | SUM | Recall | | | | | | | | |
| | | water | 0 | 0 | 18 | 11 | 2 | 0 | 0 | 0 | 0 | 31 | 0.0000 | | | | | | | | |
| | | urban | 0 | 3 | 43 | 74 | 1 | 3 | 1 | 0 | 9 | 136 | 0.0271 | | | | | | | | |
| | | rice paddy | 1 | 7 | 2489 | 284 | 19 | 19 | 9 | 0 | 46 | 0 | 2784 | 0.8908 | | | | | | | |
| | | crop | 1 | 8 | 682 | 475 | 16 | 28 | 21 | 0 | 98 | 1 | 1330 | 0.3571 | | | | | | | |
| | | grass | 0 | 0 | 88 | 42 | 6 | 11 | 7 | 0 | 38 | 0 | 192 | 0.0313 | | | | | | | |
| | | DHF | 0 | 0 | 83 | 46 | 2 | 13 | 7 | 0 | 50 | 0 | 210 | 0.0619 | | | | | | | |
| | | DNF | 0 | 0 | 63 | 50 | 6 | 18 | 5 | 0 | 76 | 0 | 218 | 0.0229 | | | | | | | |
| | | ERF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None | | | | | | | |
| | | ENF | 0 | 0 | 95 | 87 | 14 | 20 | 17 | 0 | 138 | 1 | 369 | 0.3636 | | | | | | | |
| | | barmland | 0 | 0 | 3 | 3 | 0 | 0 | 0 | 0 | 4 | 0 | 10 | 0.0000 | | | | | | | |
| | SUM | 2 | 18 | 3586 | 992 | 86 | 112 | 67 | 0 | 405 | 2 | 5290 | | | | | | | | | |
| Precision | | 0.0000 | | 0.1667 | | 0.6989 | | 0.4788 | | 0.0909 | | 0.1161 | | 0.0746 | | None | | 0.2903 | | 0.0000 | |
| Name | | exp_2 | | Over Accuracy | | 0.62540854 | | Kappa Coefficient | | 0.36801541 | | | | | | | | | | | |
| Reference | | water | urban | rice paddy | crop | grass | Precision | DNF | ERF | ENF | barmland | SUM | Recall | | | | | | | | |
| | | water | 0 | 0 | 14 | 17 | 0 | 1 | 1 | 0 | 0 | 33 | 0.0000 | | | | | | | | |
| | | urban | 0 | 11 | 50 | 115 | 0 | 0 | 0 | 0 | 1 | 0 | 177 | 0.0621 | | | | | | | |
| | | rice paddy | 1 | 1 | 3119 | 389 | 2 | 1 | 3 | 0 | 12 | 0 | 3439 | 0.9069 | | | | | | | |
| | | crop | 1 | 7 | 745 | 858 | 3 | 11 | 6 | 0 | 57 | 0 | 1688 | 0.5883 | | | | | | | |
| | | grass | 2 | 0 | 107 | 99 | 2 | 5 | 2 | 0 | 48 | 0 | 265 | 0.0075 | | | | | | | |
| | | DHF | 0 | 0 | 89 | 118 | 0 | 7 | 7 | 0 | 58 | 0 | 299 | 0.0254 | | | | | | | |
| | | DNF | 1 | 1 | 44 | 127 | 1 | 5 | 3 | 0 | 76 | 0 | 258 | 0.0116 | | | | | | | |
| | | ERF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None | | | | | | | |
| | | ENF | 0 | 0 | 85 | 268 | 1 | 11 | 10 | 0 | 160 | 0 | 475 | 0.3368 | | | | | | | |
| | | barmland | 0 | 0 | 2 | 13 | 0 | 1 | 0 | 0 | 1 | 0 | 17 | 0.0000 | | | | | | | |
| | SUM | 3 | 20 | 4255 | 1879 | 9 | 42 | 32 | 0 | 413 | 0 | 6611 | | | | | | | | | |
| Precision | | 0.0000 | | 0.5506 | | 0.7339 | | 0.4576 | | 0.2222 | | 0.1667 | | 0.0938 | | None | | 0.3854 | | None | |
| Name | | exp_3 | | Over Accuracy | | 0.6410 | | Kappa Coefficient | | 0.4178 | | | | | | | | | | | |
| Reference | | water | urban | rice paddy | crop | grass | Precision | DNF | ERF | ENF | barmland | SUM | Recall | | | | | | | | |
| | | water | 0 | 0 | 1 | 24 | 0 | 0 | 0 | 0 | 1 | 0 | 31 | 0.1413 | | | | | | | |
| | | urban | 0 | 7 | 23 | 161 | 1 | 0 | 1 | 0 | 1 | 0 | 136 | 0.0515 | | | | | | | |
| | | rice paddy | 2 | 7 | 3445 | 286 | 10 | 5 | 10 | 0 | 29 | 0 | 2784 | 0.8751 | | | | | | | |
| | | crop | 3 | 25 | 401 | 799 | 17 | 20 | 12 | 0 | 53 | 0 | 1330 | 0.6008 | | | | | | | |
| | | grass | 0 | 0 | 58 | 82 | 9 | 10 | 8 | 0 | 25 | 0 | 192 | 0.0409 | | | | | | | |
| | | DHF | 0 | 1 | 44 | 161 | 15 | 11 | 7 | 0 | 31 | 0 | 210 | 0.0524 | | | | | | | |
| | | DNF | 0 | 1 | 27 | 163 | 12 | 6 | 11 | 0 | 58 | 0 | 218 | 0.0505 | | | | | | | |
| | | ERF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None | | | | | | | |
| | | ENF | 0 | 0 | 40 | 178 | 12 | 9 | 26 | 0 | 164 | 0 | 369 | 0.2318 | | | | | | | |
| | | barmland | 0 | 0 | 3 | 5 | 0 | 0 | 0 | 0 | 2 | 0 | 10 | 0.0000 | | | | | | | |
| | SUM | 10 | 41 | 5644 | 1679 | 76 | 61 | 75 | 0 | 304 | 0 | 5290 | | | | | | | | | |
| Precision | | 0.5680 | | 0.1707 | | 0.8032 | | 0.4759 | | 0.1184 | | 0.1803 | | 0.1467 | | None | | 0.3421 | | None | |
| Name | | exp_4 | | Over Accuracy | | 0.6214 | | Kappa Coefficient | | 0.3794 | | | | | | | | | | | |
| Reference | | water | urban | rice paddy | crop | grass | Precision | DNF | ERF | ENF | barmland | SUM | Recall | | | | | | | | |
| | | water | 2 | 0 | 2 | 26 | 1 | 1 | 0 | 0 | 1 | 0 | 33 | 0.0606 | | | | | | | |
| | | urban | 1 | 7 | 25 | 143 | 1 | 0 | 0 | 0 | 3 | 0 | 177 | 0.0395 | | | | | | | |
| | | rice paddy | 4 | 5 | 2940 | 465 | 10 | 4 | 1 | 0 | 9 | 1 | 3439 | 0.8549 | | | | | | | |
| | | crop | 0 | 25 | 557 | 1048 | 18 | 5 | 7 | 0 | 26 | 2 | 1688 | 0.6209 | | | | | | | |
| | | grass | 1 | 0 | 88 | 131 | 15 | 9 | 3 | 0 | 18 | 0 | 265 | 0.0566 | | | | | | | |
| | | DHF | 0 | 1 | 59 | 178 | 29 | 14 | 3 | 0 | 15 | 0 | 299 | 0.0468 | | | | | | | |
| | | DNF | 0 | 1 | 33 | 165 | 2 | 6 | 14 | 0 | 37 | 0 | 258 | 0.0543 | | | | | | | |
| | | ERF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None | | | | | | | |
| | | ENF | 1 | 2 | 66 | 381 | 13 | 8 | 11 | 0 | 93 | 0 | 475 | 0.1938 | | | | | | | |
| | | barmland | 0 | 0 | 1 | 13 | 0 | 1 | 0 | 0 | 2 | 0 | 17 | 0.0000 | | | | | | | |
| | SUM | 9 | 41 | 3771 | 2447 | 80 | 47 | 39 | 0 | 304 | 3 | 6611 | | | | | | | | | |
| Precision | | 0.2222 | | 0.1707 | | 0.7796 | | 0.6283 | | 0.1667 | | 0.2079 | | 0.3590 | | None | | 0.4559 | | 0.0000 | |

図 4-15 exp_1~exp_4 のクラス分類結果

中分解能衛星画像の有無による分類精度への影響

オブジェクト特徴量付きの高分解能衛星画像においては exp_1 と exp_2 を、スペクトル値のみの高分解能衛星画像においては exp_3 と exp_4 を比較することで、中分解能衛星画像を用いた場合と用いない場合の結果を比較することができる。exp_1 と exp_2 の比較に

においては、中分解能衛星画像を用いた exp_2 の方が高い分類精度（Over accuracy）が得られた。一方で、exp_3 と exp_4 の比較においては、中分解能衛星画像を用いない exp_3 の方が高い分類精度が得られた。

高分解能衛星画像のオブジェクト特徴量の有無による分類精度への影響

中分解能衛星画像を用いない場合においては exp_1 と exp_3 を、中分解能衛星画像を用いた場合においては exp_2 と exp_4 を比較することで、高分解能衛星画像においてオブジェクト特徴量を用いた場合と用いない場合の結果を比較することができる。exp_1 と exp_3 の比較においては、オブジェクト特徴量を用いない exp_3 の方が高い分類精度が得られている。一方で、exp_2 と exp_4 の比較においては、オブジェクト特徴量を用いる exp_2 の方が高い分類精度が得られた。

4つの検証結果を通して

この 4 つの検証結果においては、exp_3, exp_2, exp_4, exp_1 の順で高い分類精度が得られた。これらの検証結果の中では、スペクトル値のみの高分解能衛星画像のみを用いた exp_3 が最も高い分類精度 64.1% が得られており、特徴量付きの高分解能衛星画像のみを用いた exp_1 が最も低い分類精度 59.1% が得られた。しかしながら、水田のデータ数がほぼ半分を占めている一方で水域や裸地のデータはほとんど無く、それぞれの土地被覆クラスのデータ数に大きな偏りがある。また、常緑広葉樹（EBF）に至ってはデータ数が 0 であ流という問題点がある。

4.5 検証Ⅱ

検証Ⅰで利用した土地被覆図は森林を常緑広葉樹、常緑針葉樹、落葉広葉樹、落葉針葉樹の 4 種類に分類していた。これは、同一地点複数時期の画像を用いることで分類が可能となるが、本研究のように 1 枚の画像から分類する際には困難である。そのため、常緑広葉樹、常緑針葉樹、落葉広葉樹、落葉針葉樹の 4 クラスを森林という 1 クラスにまとめた上で出力クラス 7 のデータセットによる検証を行った。

4.5.1 データセット

本検証で用いたデータセットの一覧を以下に示す（表 4-12）．続けて、用いたデータセットの詳細を記す．

表 4-12 検証Ⅱで用いたデータセット

| データセット名 | 衛星画像 | クラス数 | 水増し | オブジェクト特徴量 | データ数 |
|--------------------|------|------|-----|-----------|-------|
| Dataset-L2 | 中分解能 | 7 | × | × | 6806 |
| Dataset-H2 | 高分解能 | 7 | × | × | 26446 |
| Dataset-H2F | 高分解能 | 7 | × | ○ | 26446 |

Dataset-L2

常緑広葉樹，常緑針葉樹，落葉広葉樹，落葉針葉樹の 4 クラスを森林という 1 クラスにまとめた上で，Dataset-L1 と同様のデータセットを作成した．

Dataset-H2

常緑広葉樹，常緑針葉樹，落葉広葉樹，落葉針葉樹の 4 クラスを森林という 1 クラスにまとめた上で，Dataset-H1 と同様のデータセットを作成した．

Dataset-H2F

Dataset-H2 にセグメンテーションにより得られたオブジェクト特徴量を付与したものである．

4.5.2 検証条件

検証条件を以下の表に示す（表 4-13）．データセット項における「+」は，複数のデータセットを混合して検証したことを意味する．

表 4-13 検証Ⅱの検証条件

| 検証名 | データセット |
|--------------|------------------------|
| exp_5 | dataset-H2F |
| exp_6 | dataset-H2F+dataset-L2 |
| exp_7 | dataset-H2 |
| exp_8 | dataset-H2+dataset-L2 |

4.5.3 検証結果

出力クラス 7，データ水増し無しのデータセット dataset-H2，dataset-H2F，dataset-L2 の 3 種類を用いた検証結果（exp_5，exp_6，exp_7，exp_8）を示す．

SPP-net を用いた各検証条件の学習回数と訓練時とテスト時における分類精度と誤差値の関係性を示す（図 4-16）．続けて，SPP-net を用いた各検証条件の学習回数とテスト時におけるクラス分類精度の関係性を示す（図 4-17）．続けて，epoch=30 のモデルを用いた際の各検証条件のテストデータの分類結果を示す（図 4-18）．

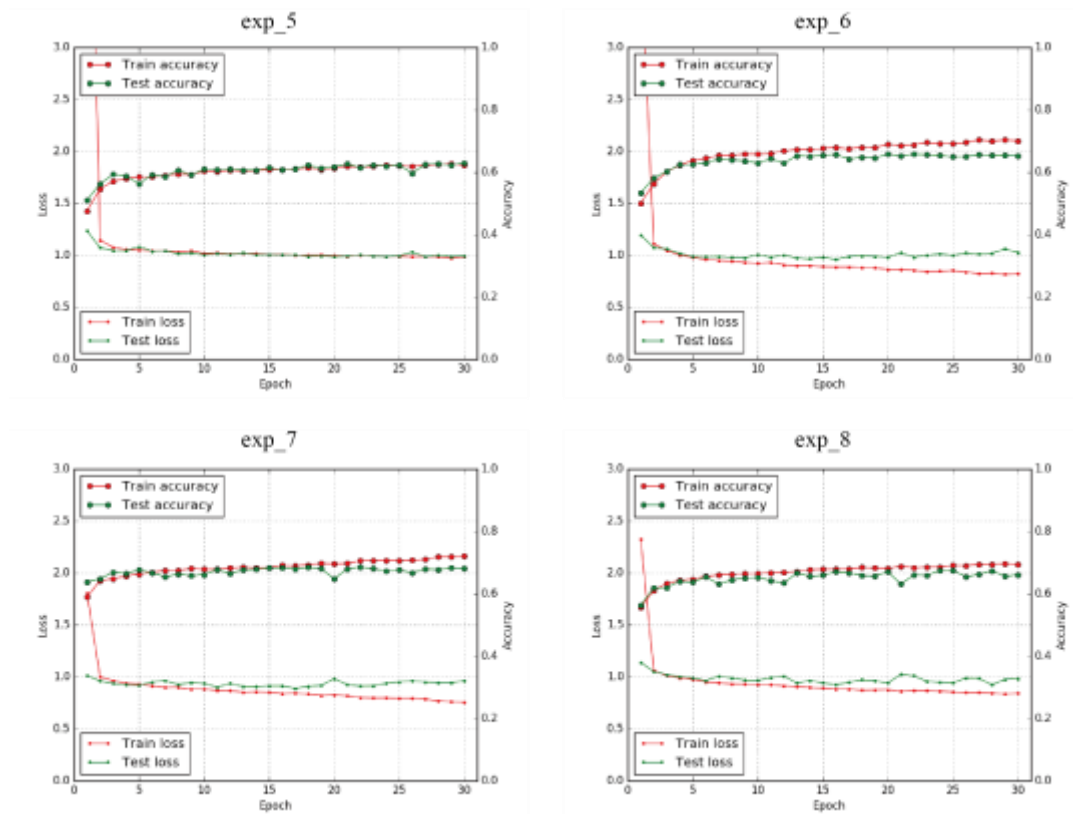


図 4-16 exp_5~exp_8 における学習経過




図 4-17 exp_5~exp_8 におけるクラス分類精度

| Name | | exp_5 | | Over Accuracy | | 0.6327 | | Kappa Coefficient | | 0.3881 | |
|-----------|------------|------------|-------|---------------|--------|--------|--------|-------------------|------|--------|--|
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 0 | 0 | 5 | 22 | 0 | 4 | 0 | 31 | 0.0000 | |
| | urban | 0 | 0 | 48 | 72 | 0 | 16 | 0 | 136 | 0.0000 | |
| | rice paddy | 0 | 0 | 2361 | 377 | 1 | 55 | 0 | 2794 | 0.3450 | |
| | crop | 0 | 0 | 492 | 677 | 1 | 160 | 0 | 1330 | 0.5090 | |
| | grass | 0 | 0 | 48 | 96 | 0 | 48 | 0 | 192 | 0.0000 | |
| | forest | 0 | 0 | 95 | 393 | 0 | 389 | 0 | 797 | 0.3877 | |
| | bareland | 0 | 0 | 4 | 4 | 0 | 2 | 0 | 10 | 0.0000 | |
| | SUM | 0 | 0 | 3053 | 1641 | 2 | 594 | 0 | 5290 | | |
| Precision | | None | None | 0.7733 | 0.4126 | 0.0000 | 0.5202 | None | | | |

| Name | | exp_6 | | Over Accuracy | | 0.6485 | | Kappa Coefficient | | 0.4140 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|------|--------|--|
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 1 | 1 | 12 | 13 | 0 | 6 | 0 | 33 | 0.0303 | |
| | urban | 0 | 8 | 53 | 108 | 0 | 8 | 0 | 177 | 0.0452 | |
| | rice paddy | 1 | 6 | 3032 | 307 | 6 | 87 | 0 | 3439 | 0.3817 | |
| | crop | 1 | 33 | 729 | 725 | 4 | 196 | 0 | 1688 | 0.4295 | |
| | grass | 0 | 1 | 92 | 63 | 1 | 108 | 0 | 265 | 0.0038 | |
| | forest | 0 | 5 | 197 | 275 | 8 | 546 | 1 | 1032 | 0.5291 | |
| | bareland | 0 | 0 | 6 | 7 | 0 | 4 | 0 | 17 | 0.0000 | |
| | SUM | 3 | 54 | 4121 | 1498 | 19 | 955 | 1 | 6651 | | |
| Precision | | 0.3333 | 0.1481 | 0.7357 | 0.4840 | 0.0526 | 0.5717 | 0.0000 | | | |

| Name | | exp_7 | | Over Accuracy | | 0.6784 | | Kappa Coefficient | | 0.4672 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|------|--------|--|
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 2 | 0 | 3 | 22 | 1 | 3 | 0 | 31 | 0.0645 | |
| | urban | 0 | 12 | 19 | 94 | 0 | 10 | 1 | 136 | 0.0882 | |
| | rice paddy | 0 | 7 | 2478 | 241 | 3 | 65 | 0 | 2794 | 0.3869 | |
| | crop | 0 | 29 | 436 | 696 | 12 | 155 | 2 | 1330 | 0.5233 | |
| | grass | 0 | 0 | 64 | 52 | 10 | 65 | 1 | 192 | 0.0521 | |
| | forest | 0 | 3 | 102 | 287 | 12 | 391 | 2 | 797 | 0.4906 | |
| | bareland | 0 | 0 | 3 | 3 | 1 | 3 | 0 | 10 | 0.0000 | |
| | SUM | 2 | 51 | 3105 | 1395 | 39 | 692 | 6 | 5290 | | |
| Precision | | 1.0000 | 0.2351 | 0.7981 | 0.4989 | 0.2564 | 0.5650 | 0.0000 | | | |

| Name | | exp_8 | | Over Accuracy | | 0.6594 | | Kappa Coefficient | | 0.4370 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|------|--------|--|
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 0 | 0 | 5 | 20 | 0 | 8 | 0 | 33 | 0.0000 | |
| | urban | 1 | 11 | 42 | 115 | 0 | 8 | 0 | 177 | 0.0621 | |
| | rice paddy | 0 | 1 | 3036 | 274 | 7 | 121 | 0 | 3439 | 0.3828 | |
| | crop | 0 | 13 | 705 | 791 | 4 | 264 | 1 | 1688 | 0.4153 | |
| | grass | 0 | 1 | 92 | 37 | 8 | 127 | 0 | 265 | 0.0302 | |
| | forest | 0 | 5 | 182 | 290 | 15 | 630 | 0 | 1032 | 0.6105 | |
| | bareland | 0 | 1 | 3 | 6 | 1 | 6 | 0 | 17 | 0.0000 | |
| | SUM | 1 | 32 | 4065 | 1353 | 35 | 1164 | 1 | 6651 | | |
| Precision | | 0.0000 | 0.3438 | 0.7469 | 0.5181 | 0.2286 | 0.5412 | 0.0000 | | | |

図 4-18 exp_5~exp_8 のクラス分類結果

中分解能衛星画像の有無による分類精度への影響

オブジェクト特徴量付きの高分解能衛星画像においては exp_5 と exp_6 を、スペクトル値のみの高分解能衛星画像においては exp_7 と exp_8 を比較することで、中分解能衛星画像を用いた場合と用いない場合の結果を比較することができる。exp_5 と exp_6 の比較においては、中分解能衛星画像を用いた exp_6 の方が高い分類精度が得られた。一方で、exp_7 と exp_8 の比較においては、中分解能衛星画像を用いない exp_7 の方が高い分類精度が得られた。

高分解能衛星画像のオブジェクト特徴量の有無による分類精度への影響

中分解能衛星画像を用いない場合においては exp_5 と exp_7 を、中分解能衛星画像を用いた場合においては exp_6 と exp_8 を比較することで、高分解能衛星画像においてオブジェクト特徴量を用いた場合と用いない場合の結果を比較することができる。exp_5 と exp_7 の比較においては、オブジェクト特徴量を用いない exp_7 の方が高い分類精度が得られて

いる．一方で，exp_6 と exp_8 の比較においても同様に，オブジェクト特徴量を用いない exp_8 の方が高い分類精度が得られた．

4つの検証結果を通して

この4つの検証結果においては，exp_7, exp_8, exp_6, exp_5 の順で高い分類精度が得られた．これらの検証結果の中では，スペクトル値のみの高分解能衛星画像のみを用いた exp_7 が最も高い分類精度 67.8%が得られており，特徴量付きの高分解能衛星画像のみを用いた exp_5 が最も低い分類精度 63.3%が得られた．しかしながら，依然として土地被覆クラスのデータ数に大きな偏りがある．

4.6 検証Ⅲ

対象地域は水田，畑地，森林が多く，都市や水域の土地被覆が少ない．このように土地被覆クラスの分布に偏りがあると，適切な分類が行われず分類精度を下げてしまう原因となることが考えられる．そのため，出力クラスは検証Ⅱと同様7クラスにして，データ数が少ないクラスに対してはデータの水増しを行った．

4.6.1 データセット

本検証で用いたデータセットの一覧を以下に示す（表 4-14）．続けて，用いたデータセットの詳細を記す．

表 4-14 検証Ⅲで用いたデータセット

| データセット名 | 衛星画像 | クラス数 | 水増し | オブジェクト特徴量 | データ数 |
|--------------------|------|------|-----|-----------|-------|
| Dataset-L3 | 中分解能 | 7 | ○ | × | 21502 |
| Dataset-H3 | 高分解能 | 7 | ○ | × | 80086 |
| Dataset-H3F | 高分解能 | 7 | ○ | ○ | 80888 |

Dataset-L3

Dataset-L2 に対して，データセットの中で最も多く含まれるクラスのデータ数（N 個とする）をまず求め，データ数が N 個の半分以下のクラスに対してはデータ数が $0.7 \sim 0.9N$ となるようデータの水増しを行った．この際の水増しデータは元データにガウスノイズ（平均：0，分散：元データの平均値の 0.1 倍）を加えたものとした．

Dataset-H3

Dataset-L3 と同様の水増しを Dataset-H2 に対して行ったものである．

Dataset-H3F

Dataset-H3 にセグメンテーションにより得られたオブジェクト特徴量を付与したものである．

4.6.2 検証条件

検証条件を以下の表に示す（表 4-15）. データセット項における「+」は、複数のデータセットを混合して検証したことを意味する.

表 4-15 検証Ⅲの検証条件

| 検証名 | データセット |
|--------|------------------------|
| exp_9 | dataset-H3F |
| exp_10 | dataset-H3F+dataset-L3 |
| exp_11 | dataset-H3 |
| exp_12 | dataset-H3+dataset-L3 |

4.6.3 検証結果

出力クラス 7, データ水増し有りのデータセット dataset-H3, dataset-H3F, dataset-L3 の3種類を用いた検証結果（exp_9, exp_10, exp_11, exp_12）を示す.

SPP-net を用いた各検証条件の学習回数と訓練時とテスト時における分類精度と誤差値の関係性を示す（図 4-19）. 続けて, SPP-net を用いた各検証条件の学習回数とテスト時におけるクラス分類精度の関係性を示す（図 4-20）. 続けて, epoch=30 のモデルを用いた際の各検証条件のテストデータの分類結果を示す（図 4-21）.

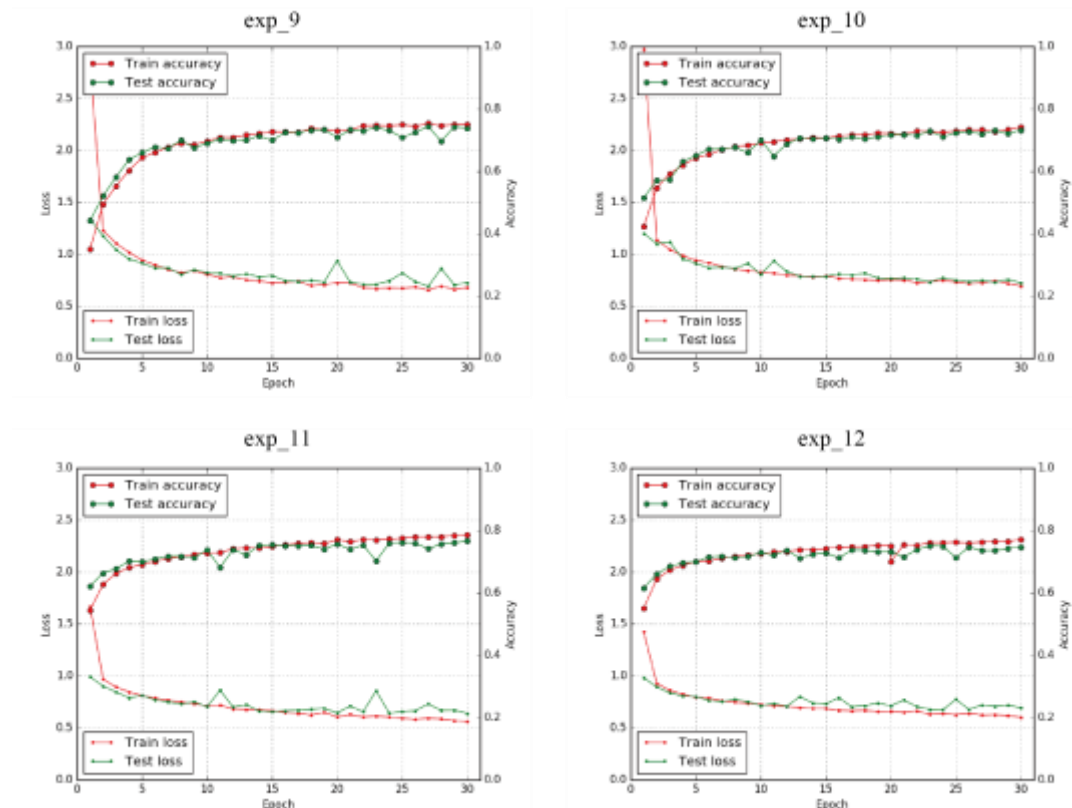


図 4-19 exp_9~exp_12 における学習経過




図 4-20 exp_9~exp_12 におけるクラス分類精度

| Name | | exp_9 | | Over Accuracy | | 0.7353 | | Kappa Coefficient | | 0.6905 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|-------|--------|--------|
| Reference | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| | water | 1996 | 102 | 1 | 37 | 54 | 19 | 21 | 2230 | | 0.8951 |
| | urban | 12 | 2006 | 9 | 222 | 103 | 57 | 62 | 2471 | | 0.8118 |
| | rice paddy | 3 | 6 | 2230 | 384 | 8 | 94 | 0 | 2725 | | 0.8183 |
| | crop | 12 | 149 | 444 | 1134 | 83 | 346 | 3 | 2171 | | 0.5223 |
| | grass | 16 | 238 | 84 | 163 | 1283 | 385 | 13 | 2102 | | 0.5723 |
| | forest | 5 | 102 | 177 | 448 | 294 | 1325 | 7 | 2358 | | 0.5619 |
| | bareland | 3 | 60 | 2 | 21 | 16 | 17 | 2062 | 2121 | | 0.9439 |
| | SUM | 2047 | 2663 | 2947 | 2409 | 1761 | 2243 | 2108 | 16178 | | |
| Precision | | 0.9751 | 0.7533 | 0.7567 | 0.4707 | 0.6831 | 0.5907 | 0.9497 | | | |
| Name | | exp_10 | | Over Accuracy | | 0.7356 | | Kappa Coefficient | | 0.6907 | |
| Reference | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| | water | 2540 | 114 | 20 | 43 | 67 | 40 | 8 | 2832 | | 0.8969 |
| | urban | 19 | 2394 | 46 | 362 | 125 | 165 | 22 | 3133 | | 0.7641 |
| | rice paddy | 3 | 1 | 3032 | 305 | 5 | 67 | 0 | 3413 | | 0.8884 |
| | crop | 7 | 62 | 723 | 1505 | 53 | 429 | 0 | 2779 | | 0.5416 |
| | grass | 6 | 216 | 142 | 231 | 1515 | 613 | 6 | 2729 | | 0.5551 |
| | forest | 3 | 61 | 281 | 699 | 220 | 1599 | 1 | 2855 | | 0.5569 |
| | bareland | 11 | 108 | 2 | 34 | 35 | 35 | 2422 | 2647 | | 0.9150 |
| | SUM | 2589 | 2956 | 4246 | 3179 | 2020 | 2939 | 2459 | 20388 | | |
| Precision | | 0.9811 | 0.8099 | 0.7141 | 0.4734 | 0.7500 | 0.5410 | 0.9850 | | | |
| Name | | exp_11 | | Over Accuracy | | 0.7676 | | Kappa Coefficient | | 0.7284 | |
| Reference | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| | water | 1844 | 66 | 2 | 28 | 35 | 26 | 15 | 2016 | | 0.9147 |
| | urban | 38 | 1728 | 24 | 180 | 111 | 107 | 24 | 2212 | | 0.7812 |
| | rice paddy | 1 | 1 | 2393 | 181 | 3 | 152 | 1 | 2732 | | 0.8759 |
| | crop | 1 | 69 | 467 | 844 | 40 | 703 | 5 | 2169 | | 0.4076 |
| | grass | 10 | 121 | 48 | 84 | 1654 | 503 | 18 | 2438 | | 0.6784 |
| | forest | 5 | 48 | 86 | 219 | 192 | 1632 | 2 | 2184 | | 0.7473 |
| | bareland | 2 | 24 | 4 | 13 | 35 | 28 | 2161 | 2267 | | 0.9532 |
| | SUM | 1901 | 2057 | 3024 | 1589 | 2070 | 3151 | 2226 | 16018 | | |
| Precision | | 0.9700 | 0.8401 | 0.7913 | 0.5563 | 0.7990 | 0.5179 | 0.9708 | | | |
| Name | | exp_12 | | Over Accuracy | | 0.7451 | | Kappa Coefficient | | 0.7021 | |
| Reference | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| | water | 2384 | 69 | 2 | 30 | 53 | 32 | 6 | 2576 | | 0.9255 |
| | urban | 133 | 2621 | 22 | 220 | 253 | 123 | 21 | 2793 | | 0.7236 |
| | rice paddy | 3 | 4 | 2854 | 454 | 4 | 152 | 1 | 3472 | | 0.8320 |
| | crop | 27 | 125 | 503 | 1310 | 123 | 664 | 5 | 2757 | | 0.4752 |
| | grass | 61 | 168 | 81 | 125 | 2972 | 498 | 9 | 3014 | | 0.6875 |
| | forest | 13 | 88 | 126 | 393 | 362 | 1804 | 1 | 2787 | | 0.6473 |
| | bareland | 19 | 66 | 1 | 19 | 72 | 26 | 2626 | 2829 | | 0.9282 |
| | SUM | 2640 | 2541 | 3589 | 2551 | 2939 | 3299 | 2669 | 20228 | | |
| Precision | | 0.9030 | 0.7954 | 0.7952 | 0.5135 | 0.7050 | 0.5468 | 0.9839 | | | |

図 4-21 exp_9~exp_12 のクラス分類結果

中分解能衛星画像の有無による分類精度への影響

オブジェクト特徴量付きの高分解能衛星画像においては exp_9 と exp_10 を、スペクトル値のみの高分解能衛星画像においては exp_11 と exp_12 を比較することで、中分解能衛星

画像を用いた場合と用いない場合の結果を比較することができる。exp_9 と exp_10 の比較においては、中分解能衛星画像を用いた exp_10 の方がわずかに高い分類精度が得られたがこの差は誤差とも取れる。一方で、exp_11 と exp_12 の比較においては、中分解能衛星画像を用いない exp_11 の方が高い分類精度が得られた。

高分解能衛星画像のオブジェクト特徴量の有無による分類精度への影響

中分解能衛星画像を用いない場合においては exp_9 と exp_11 を、中分解能衛星画像を用いた場合においては exp_10 と exp_12 を比較することで、高分解能衛星画像においてオブジェクト特徴量を用いた場合と用いない場合の結果を比較することができる。exp_9 と exp_11 の比較においては、オブジェクト特徴量を用いない exp_11 の方が高い分類精度が得られている。一方で、exp_10 と exp_12 の比較においても同様に、オブジェクト特徴量を用いない exp_12 の方が高い分類精度が得られた。

4つの検証結果を通して

この4つの検証結果においては、exp_11, exp_12, exp_10, exp_9 の順で高い分類精度が得られた。これらの検証結果の中では、スペクトル値のみの高分解能衛星画像のみを用いた exp_11 が最も高い分類精度 76.8% が得られており、特徴量付きの高分解能衛星画像のみを用いた exp_9 が最も低い分類精度 73.5% が得られた。データの水増しにより土地被覆クラスのデータ数の偏りを減らすことにより、分類精度は大きく向上している。

4.7 従来手法との比較

従来手法との比較を行うため、最尤推定を用いたピクセルベースの土地被覆分類も行った。従来手法の検証条件を以下に示す（表 4-16）。

表 4-16 従来手法の検証条件

| 検証名 | データセット |
|--------|------------|
| exp_m1 | dataset-L1 |
| exp_m2 | dataset-H1 |
| exp_m3 | dataset-L2 |
| exp_m4 | dataset-H2 |
| exp_m5 | dataset-L3 |
| exp_m6 | dataset-H3 |

提案手法による分類結果とピクセルベースの最尤推定による分類結果の比較を示す。クラス数 10 のデータセットを用いた exp_m1 と exp_m2 におけるテストデータの分類結果、クラス数 7 のデータセットを用いた exp_m3 と exp_m4 におけるテストデータの分類結果、クラス数 7 でデータ水増しを行ったデータセットを用いた exp_m5 と exp_m6 におけるテストデータの分類結果をそれぞれ以下に示す。（図 4-22, 図 4-23, 図 4-24）。

| Name | | exp_m1 | | Accuracy | | 0.6389 | | Kappa Coefficient | | 0.4194 | | | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|------|--------|----------|------|--------|
| | | Prediction | | | | | | | | | | | Recall |
| | | water | urban | rice paddy | crop | grass | DBF | DNF | EBF | ENF | bareland | SUM | |
| Reference | water | 0 | 0 | 0 | 5 | 0 | 1 | 0 | 0 | 2 | 0 | 8 | 0.0000 |
| | urban | 0 | 4 | 12 | 23 | 0 | 0 | 0 | 0 | 0 | 0 | 39 | 0.1826 |
| | rice paddy | 0 | 0 | 686 | 68 | 8 | 0 | 0 | 0 | 5 | 0 | 687 | 0.8821 |
| | crop | 5 | 2 | 131 | 268 | 7 | 0 | 0 | 0 | 24 | 0 | 370 | 0.5432 |
| | grass | 0 | 0 | 15 | 19 | 8 | 2 | 0 | 0 | 7 | 0 | 51 | 0.1566 |
| | DBF | 1 | 0 | 14 | 16 | 8 | 6 | 0 | 0 | 18 | 0 | 63 | 0.0952 |
| | DNF | 0 | 1 | 7 | 8 | 4 | 3 | 0 | 0 | 25 | 0 | 48 | 0.0000 |
| | EBF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None |
| | ENF | 0 | 0 | 8 | 32 | 4 | 5 | 0 | 0 | 44 | 0 | 93 | 0.4751 |
| | bareland | 0 | 0 | 0 | 3 | 0 | 0 | 0 | 0 | 0 | 0 | 3 | 0.0000 |
| SUM | 6 | 7 | 793 | 373 | 39 | 17 | 0 | 0 | 125 | 0 | 1362 | | |
| Precision | | 0.0000 | 0.5714 | 0.7842 | 0.5389 | 0.2851 | 0.3529 | None | None | 0.3520 | None | | |
| Name | | exp_m2 | | Over Accuracy | | 0.6174 | | Kappa Coefficient | | 0.3493 | | | |
| | | Prediction | | | | | | | | | | | Recall |
| | | water | urban | rice paddy | crop | grass | DBF | DNF | EBF | ENF | bareland | SUM | |
| Reference | water | 0 | 0 | 10 | 20 | 1 | 0 | 0 | 0 | 0 | 0 | 31 | 0.0000 |
| | urban | 0 | 11 | 38 | 81 | 2 | 0 | 0 | 0 | 4 | 0 | 136 | 0.0809 |
| | rice paddy | 0 | 7 | 2529 | 199 | 18 | 0 | 0 | 0 | 41 | 0 | 2794 | 0.9852 |
| | crop | 0 | 22 | 633 | 571 | 42 | 9 | 0 | 0 | 53 | 0 | 1336 | 0.4293 |
| | grass | 0 | 0 | 67 | 53 | 29 | 5 | 0 | 0 | 38 | 0 | 192 | 0.1510 |
| | DBF | 0 | 0 | 75 | 73 | 32 | 3 | 0 | 0 | 25 | 0 | 239 | 0.0643 |
| | DNF | 0 | 1 | 47 | 71 | 12 | 7 | 0 | 0 | 89 | 0 | 218 | 0.0000 |
| | EBF | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | 0 | None |
| | ENF | 0 | 0 | 82 | 143 | 14 | 5 | 0 | 0 | 123 | 0 | 369 | 0.3333 |
| | bareland | 0 | 0 | 2 | 4 | 0 | 0 | 0 | 0 | 4 | 0 | 10 | 0.0000 |
| SUM | 0 | 41 | 3483 | 1219 | 150 | 29 | 0 | 0 | 368 | 0 | 5296 | | |
| Precision | | None | 0.2683 | 0.7261 | 0.4684 | 0.1933 | 0.1034 | None | None | 0.3342 | None | | |

図 4-22 exp_m1 と exp_m2 のクラス分類結果

| Name | | exp_m3 | | Over Accuracy | | 0.6806 | | Kappa Coefficient | | 0.4884 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|------|--------|--|
| | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 0 | 0 | 0 | 5 | 0 | 3 | 0 | 8 | 0.0000 | |
| | urban | 0 | 4 | 11 | 22 | 0 | 2 | 0 | 39 | 0.1026 | |
| | rice paddy | 0 | 0 | 685 | 53 | 0 | 29 | 0 | 687 | 0.8806 | |
| | crop | 5 | 2 | 122 | 165 | 0 | 76 | 0 | 370 | 0.4459 | |
| | grass | 0 | 0 | 15 | 10 | 2 | 24 | 0 | 51 | 0.0392 | |
| | forest | 1 | 1 | 22 | 28 | 1 | 151 | 0 | 204 | 0.7402 | |
| | bareland | 0 | 0 | 0 | 3 | 0 | 0 | 0 | 3 | 0.0000 | |
| | SUM | 6 | 7 | 775 | 286 | 3 | 285 | 0 | 1362 | | |
| Precision | | 0.0000 | 0.5714 | 0.7806 | 0.5769 | 0.6667 | 0.5298 | None | | | |
| Name | | exp_m4 | | Over Accuracy | | 0.6656 | | Kappa Coefficient | | 0.4346 | |
| | | Prediction | | | | | | | | Recall | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | | |
| Reference | water | 0 | 0 | 10 | 18 | 0 | 3 | 0 | 31 | 0.0000 | |
| | urban | 0 | 11 | 38 | 77 | 2 | 8 | 0 | 136 | 0.0869 | |
| | rice paddy | 0 | 7 | 2524 | 168 | 8 | 87 | 0 | 2794 | 0.9034 | |
| | crop | 0 | 22 | 614 | 477 | 27 | 190 | 0 | 1330 | 0.3586 | |
| | grass | 0 | 0 | 64 | 20 | 21 | 87 | 0 | 192 | 0.1094 | |
| | forest | 0 | 1 | 169 | 110 | 29 | 488 | 0 | 797 | 0.6123 | |
| | bareland | 0 | 0 | 2 | 4 | 0 | 4 | 0 | 10 | 0.0000 | |
| | SUM | 0 | 41 | 3421 | 874 | 87 | 867 | 0 | 5290 | | |
| Precision | | None | 0.2683 | 0.7378 | 0.5458 | 0.2414 | 0.5629 | None | | | |

図 4-23 exp_m3 と exp_m4 のクラス分類結果

| Name | | exp_m5 | | Over Accuracy | | 0.4346 | | Kappa Coefficient | | 0.3370 | |
|-----------|------------|------------|--------|---------------|--------|--------|--------|-------------------|-------|--------|--|
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | Recall | |
| Reference | water | 238 | 95 | 0 | 15 | 63 | 143 | 38 | 592 | 0.4020 | |
| | urban | 49 | 260 | 59 | 7 | 63 | 18 | 162 | 618 | 0.4207 | |
| | rice paddy | 2 | 15 | 526 | 10 | 90 | 4 | 41 | 688 | 0.7645 | |
| | crop | 15 | 95 | 96 | 13 | 155 | 36 | 138 | 548 | 0.0237 | |
| | grass | 9 | 7 | 76 | 23 | 428 | 81 | 26 | 650 | 0.6585 | |
| | forest | 26 | 21 | 22 | 6 | 211 | 206 | 44 | 536 | 0.3843 | |
| | bareland | 38 | 217 | 23 | 35 | 69 | 38 | 159 | 579 | 0.2746 | |
| | SUM | 377 | 710 | 802 | 109 | 1079 | 526 | 608 | 4211 | | |
| Precision | | 0.6313 | 0.3662 | 0.6559 | 0.1193 | 0.3967 | 0.3916 | 0.2615 | | | |
| Name | | exp_m6 | | Over Accuracy | | 0.4486 | | Kappa Coefficient | | 0.3546 | |
| | | Prediction | | | | | | | | | |
| | | water | urban | rice paddy | crop | grass | forest | bareland | SUM | Recall | |
| Reference | water | 1353 | 217 | 52 | 13 | 79 | 268 | 34 | 2016 | 0.6711 | |
| | urban | 479 | 1063 | 322 | 21 | 107 | 54 | 166 | 2212 | 0.4806 | |
| | rice paddy | 86 | 52 | 2267 | 30 | 182 | 98 | 17 | 2732 | 0.8298 | |
| | crop | 431 | 378 | 660 | 24 | 305 | 228 | 143 | 2169 | 0.0111 | |
| | grass | 255 | 33 | 428 | 37 | 847 | 752 | 86 | 2438 | 0.3474 | |
| | forest | 349 | 70 | 173 | 26 | 393 | 1069 | 104 | 2184 | 0.4895 | |
| | bareland | 191 | 493 | 193 | 103 | 184 | 540 | 563 | 2267 | 0.2483 | |
| | SUM | 3144 | 2306 | 4095 | 254 | 2097 | 3009 | 1113 | 16018 | | |
| Precision | | 0.4303 | 0.4610 | 0.5536 | 0.0945 | 0.4039 | 0.3553 | 0.5058 | | | |

図 4-24 exp_m5 と exp_m6 のクラス分類結果

クラス数 10 のデータセットを用いた提案手法と従来手法の比較

exp_m1 と exp_m2 を比較すると、ピクセルベースの最尤推定においては、高分解能衛星画像より中分解能衛星画像を用いた方が高い分類精度が得られていることがわかる。また、同様のデータセットを用いた提案手法（exp_1~exp_4）と比較すると、提案手法による分類結果（exp_3）の方が高精度であることがわかる。

クラス数 7 のデータセットを用いた提案手法と従来手法の比較

exp_m3 と exp_m4 を比較すると、ピクセルベースの最尤推定においては、高分解能衛星画像より中分解能衛星画像を用いた方が高い分類精度が得られていることがわかる。また、同様のデータセットを用いた提案手法（exp_5~exp_8）と比較すると、従来手法による分類結果（exp_m3）の方が高精度であることがわかる。

クラス数 7 のデータセット（水増し有）を用いた提案手法と従来手法の比較

exp_m5 と exp_m6 を比較すると、ピクセルベースの最尤推定においては、高分解能衛星画像より中分解能衛星画像を用いた方が高い分類精度が得られていることがわかる。また、同様のデータセットを用いた提案手法（exp_9~exp_12）と比較すると、提案手法による分類結果（exp_11）の方が大幅に高精度であることがわかる。

4.8 考察

ここで、改めて各条件と分類精度一覧表とグラフを示す（表 4-17、図 4-25）。表中の Option はデータセットの衛星画像の分解能（L：中分解能，H：高分解能）とオブジェクト特徴量の有無（F：有り，無印：無し）を表す。

表 4-17 各検証条件と分類精度一覧

| Name | Network | Dataset | Option | Accuracy |
|--------|---------|----------|--------|----------|
| exp_1 | SPP-net | dataset1 | HF | 0.5909 |
| exp_2 | SPP-net | dataset1 | HF+L | 0.6255 |
| exp_3 | SPP-net | dataset1 | H | 0.6410 |
| exp_4 | SPP-net | dataset1 | H+L | 0.6214 |
| exp_5 | SPP-net | dataset2 | HF | 0.6327 |
| exp_6 | SPP-net | dataset2 | HF+L | 0.6485 |
| exp_7 | SPP-net | dataset2 | H | 0.6784 |
| exp_8 | SPP-net | dataset2 | H+L | 0.6594 |
| exp_9 | SPP-net | dataset3 | HF | 0.7353 |
| exp_10 | SPP-net | dataset3 | HF+L | 0.7356 |
| exp_11 | SPP-net | dataset3 | H | 0.7676 |
| exp_12 | SPP-net | dataset3 | H+L | 0.7451 |
| exp_m1 | MLC | dataset1 | L | 0.6380 |
| exp_m2 | MLC | dataset1 | H | 0.6174 |
| exp_m3 | MLC | dataset2 | L | 0.6806 |
| exp_m4 | MLC | dataset2 | H | 0.6656 |
| exp_m5 | MLC | dataset3 | L | 0.4346 |
| exp_m6 | MLC | dataset3 | H | 0.4486 |




図 4-25 各検証条件と分類精度一覧

以下では、データセットの違いによる比較、中分解能衛星画像の有無による影響、高分解能衛星画像の特徴量の有無による影響、従来手法と提案手法の分類精度の比較を行う。

4.8.1 データセット間の比較

本検証では、高分解能衛星画像におけるオブジェクト特徴量の有無と中分解能衛星画像の混合の有無を、検証Ⅰ～Ⅲの3種類のデータセットで検証した。ここでは、クラス数の変化とデータセットの水増しがどのように分類精度に影響を与えたかを示す。各データセットにおける分類精度の比較を以下に示す（図 4-26）。

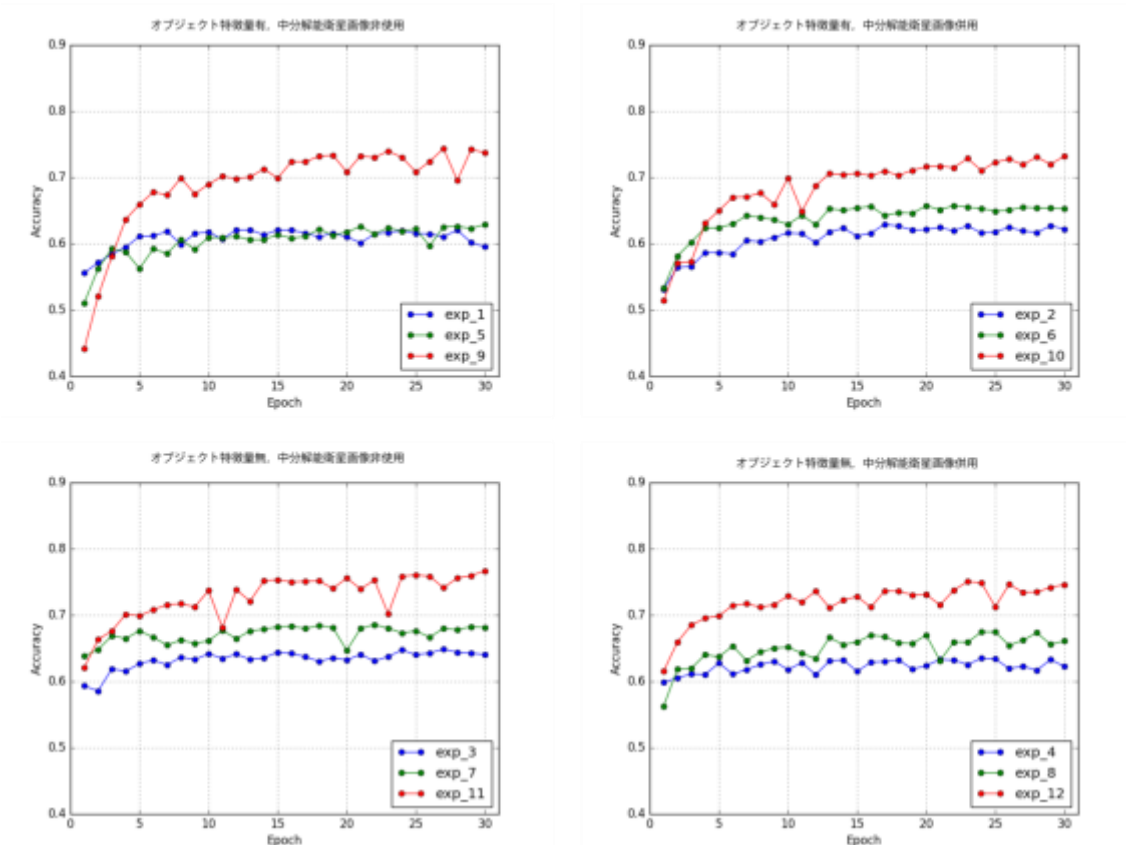


図 4-26 各データセットにおける分類精度の比較

図より、高分解能衛星画像におけるオブジェクト特徴量の有無、中分解能衛星画像の併用に問わず、7クラスの水増し有データセットを用いた場合に最も高い分類精度が得られていることがわかる。続いて7クラスのデータセットにおいて高い分類精度が得られ、10クラスのデータセットは最も低い分類精度である。また、分類精度の向上の寄与度は、10クラスから7クラスへのクラス数の減少より、データ数の水増しによる影響の方が大きいことがわかる。

提案手法においては、クラス数の減少により分類精度は向上し、期待通りの結果が得られている。さらに出現頻度の低いクラスのデータの水増しにより、クラスごとのデータ数の偏りが少なくなったことに起因して、さらなる分類精度の向上も達成している。

一方で、最尤推定を用いたピクセルベースの従来手法においては、クラス数の減少に伴い

分類精度が向上しているところまでは提案手法と同じだが、出現頻度の低いクラスのデータの増しを行うことで精度が極端に低下していることが上図よりわかる。これは、従来手法は各ピクセルのスペクトル値のみを参照してクラス分類を行っているため、増ししたデータに含まれるノイズの影響が無視できなかったのではないかと考えられる。一方で、提案手法は 50×50 のパッチを入力として与えていたため、本検証で与えた程度のノイズには頑健であったと考えられる。

4.8.2 中分解能衛星画像の有無に関して

クラス数 7 のデータセットでは、高分解能衛星画像においてオブジェクト特徴量を用いる場合には中分解能衛星画像の併用により分類精度は向上する (exp_1 と exp_2 の比較) が、オブジェクト特徴量を用いない場合には、中分解能衛星画像の併用は分類精度の低下を招く (exp_3 と exp_4 の比較) ことがわかる。クラス数 10 のデータセットにおいても、クラス数 7 のデータセットにおいても (exp_5~exp_8 の比較)、クラス数 7 (増し有) のデータセットにおいても (exp_9~exp_12 の比較)、同様の傾向が得られていた。

以上より、高分解能衛星画像においてオブジェクト特徴量を用いた場合には中分解能衛星画像の併用、オブジェクト特徴量を用いない場合には中分解能衛星画像を用いない方が分類精度は向上する。そのため、中分解能衛星画像を用いるべきかどうかは本検証だけから評価することは難しい。

このような結果が得られた原因として以下のことが考えられる。中分解能衛星画像の併用により学習時に用いることができるデータ数が増加し分類精度の向上に寄与したが、分解能が異なる衛星画像を学習データとして同一モデルに用いることにより学習すべき特徴は増加しているため十分なデータ数を学習に用いないと逆に分類精度の低下を招いてしまったと考えられる。中分解能衛星画像においては多くのデータが無料で公開されているため、これらを利用することで分類精度の向上の可能性が示唆される。また、本研究で利用した衛星画像の分解能の違いが大きすぎたことも要因の 1 つである、高分解能衛星画像の分解能が 0.31m であるのに対し、中分解能衛星画像の分解能は 15m であり、2 つの衛星画像の分解能の違いは 50 倍ある。

4.8.3 高分解能衛星画像のオブジェクト特徴量の有無に関して

クラス数 10 のデータセットでは、中分解能衛星画像併用時には高分解能衛星画像のオブジェクト特徴量を用いた方が分類精度はわずかに高い (exp_2 と exp_4 の比較) が、中分解能衛星画像非使用時には高分解能衛星画像のオブジェクト特徴量を用いない方が高い分類精度が得られる (exp_1 と exp_3 の比較)。一方で、クラス数 7 のデータセットでは、中分解能衛星画像併用時には高分解能衛星画像のオブジェクト特徴量を用いた方が分類精度は低く (exp_6 と exp_8 の比較)、中分解能衛星画像非使用時には上述と同様に高分解能衛星画像のオブジェクト特徴量を用いない方が高い分類精度が得られる (exp_5 と exp_7 の比較)。クラス数 7 (増し有) のデータセットにおいてはクラス数 7 のデータセットと同様の傾向が見られた (exp_9~exp_12 の比較)。

高分解能衛星画像のオブジェクト特徴量の有無による分類精度への影響は、分類精度の低下を招いているケースが多かった。これは、高分解能衛星画像のオブジェクト特徴量の付与によって、増加した特徴量を適切に学習することができなかったと考えられる。これはデータ数が少なかったこと、ニューラルネットワークの層が不足、などにより正しく高次の特徴が分類に適切に活用できなかったことが原因であると考えられる。また、オブジェクト特徴量の種類ごとに値の平均値や分散値が異なっていたため、これらの値を正規化することで分類精度の向上が達成する可能性も示唆される。

4.8.4 従来手法との比較

どのデータセットを用いた場合においても、最尤推定を用いたピクセルベースの従来手法より提案手法の方が高い分類精度が得られた。これは従来手法では入力がピクセルのスペクトル値だけなのに対し提案手法では対象地域を中心とした 50×50 のパッチ画像であること、分類モデルに最尤推定ではなく **SPP-net** を用いていることでより高度な分類が実現したと考えられる。しかし、計算コストに焦点を当てると、学習時間、テスト時間ともに **SPP-net** を用いた方が大きいことに留意する必要がある。

第5章 本研究の結論

本研究では、従来の土地被覆分類の課題を整理し、異分解能衛星画像を統合した土地被覆分類手法を提案し、提案手法の精度検証を行った。異分解能衛星画像の統合には、異なるピクセルサイズを持つ画像を入力しクラス分類を行うことができる SPP-net に基づく手法を構築した。ここに、本研究の成果と今後の課題を示す。

5.1 本研究の成果

異分解能衛星画像を統合した土地被覆分類手法の構築

まず、対象とする中分解能・高分解能衛星画像を用いた土地被覆分類の既往研究から、それらの特徴量を整理した。その結果に基づき、中分解能衛星画像においてはスペクトル値を用い、高分解能衛星画像においてはスペクトル値に加え、空間的特徴を考慮したオブジェクト特徴量の両者を用いることとした。オブジェクト特徴量は、画像セグメンテーションを適用し、各領域の面積や周囲長等として定義した。クラス分類手法としては、近年、注目されている畳み込みニューラルネットワーク（CNN）に基づく手法をベースとしている。本研究では、畳み込み層が2層、全結合層が2層のCNNを構築した。また、分解能の異なる画像やオブジェクト特徴量を用いることから、柔軟に入力データに対応可能な Spatial Pyramid Pooling network（SPP-net）への拡張を行った。

実データへの適用を通じた提案手法の精度検証

分解能 0.31m の WorldView-3 による高分解能衛星画像と、分解能 15m の Terra による中分解能衛星画像を用いて、提案手法の土地被覆分類の精度を検証した。その結果、出力クラス数を7とした場合、高分解能衛星画像におけるオブジェクト特徴量無しの条件において、74.5%の分類精度が得られた。これは、ピクセルベースの最尤推定を用いてクラス分類を行う従来手法の分類精度 68.1%に比べて高い分類精度であった。

一方で、提案手法において、高分解能衛星画像のみを用いた場合と高分解能衛星画像と中分解能衛星画像を併用した場合を比較したところ、高分解能衛星画像のみを用いた条件の方が高い分類精度が得られた。これは、データ数が少なかったことにより、異種データの入力によって増加した特徴量を十分に学習できていなかったことが原因であると考えられる。また、2つの衛星画像の分解能の違いが大きすぎたことも要因の1つと考えられる。

データ数の少ない土地被覆クラスのデータの拡大

データ数の少ない土地被覆クラスにおいて、元データにガウスノイズを加えたデータを作成し、学習データの拡大を行い、クラスごとのデータ数のばらつきを減らしたデータセットを作成した。このデータセットを用いた土地被覆分類は、データの拡大を行わないデータセットと比較して高い分類精度が得られた。クラス間のデータ数のばらつきが減少したことにより、適切な分類が行われたと考えられる。

高分解能衛星画像におけるオブジェクト特徴量の影響評価

空間的特性を考慮するために、高分解能衛星画像において、前処理のセグメンテーションによって得られたオブジェクト特徴量の影響を評価した。オブジェクト特徴量の有無による土地被覆分類の結果を比較し、考察を行った。その結果、オブジェクト特徴量を加えない条件においてより高い分類精度が得られた。これは、オブジェクト特徴量を追加することにより、学習すべき特徴量が増加し十分な学習が出来ず、分類精度が低下したと考えられる。

5.2 今後の課題

中分解能衛星画像の学習データの増加

本研究では、高分解能衛星画像のみを用いた場合と、高分解能衛星画像と中分解能衛星画像を併用した場合とでは、高分解能衛星画像のみを用いた場合の方が高い分類精度が得られた。これは異分解能衛星画像を統合することで学習すべき特徴が増加した一方で、それぞれの分解能の衛星画像のデータ数が不足していたため、十分な学習ができていなかったことが原因であると考えられる。そこで、より多くの衛星画像を用いて学習したモデルによる土地被覆分類を行うことで、精度にどのような影響が生じるか確認を行う必要がある。

高分解能衛星画像におけるオブジェクト特徴量の正規化

本検証で用いた高分解能衛星画像におけるオブジェクト特徴量は特徴量の種類ごとに値の範囲が大きく異なっていた。これは、高分解能衛星画像におけるオブジェクト特徴量を加えた条件で分類精度が低下した1つの要因であると考えられる。そのため、オブジェクト特徴量の正規化を行う必要がある。

高分解能衛星画像におけるオブジェクト特徴量の組み合わせ

本検証では、セグメンテーションより得られたオブジェクトから5種のオブジェクト特徴量を用いたが、他にも使用できるオブジェクト特徴量は存在する。そこで、提案手法に最適なオブジェクト特徴量の組み合わせを検証する必要がある。

3種類以上の異なる分解能を持つ衛星画像の統合

本検証では分解能 0.31m の高分解能衛星画像と分解能 15m の中分解能衛星画像の2種類の衛星画像を用いて土地被覆分類を行なったが、提案手法は3種類以上の異分解能衛星画像の統合も可能である。そのため、より多くの異分解能衛星画像を統合することで、分類精度へどのような影響を及ぼすか確認する必要がある。

中分解能衛星画像を用いたプレトレーニング

本検証で用いた衛星画像と正解データは用意されているごく一部である。Terraにより撮影された中分解能衛星画像は、膨大な枚数がウェブ上に無料で公開されており、JAXAによって公開されている土地被覆分類図も日本全国において作成されている。そのため、これらのデータを用いて、SPP-netをプレトレーニングすることで、より分類精度の高いモデルを作成することが考えられる。

参考文献

- ANDERSON, JAMES RICHARD. "A LAND USE AND LAND COVER CLASSIFICATION SYSTEM FOR USE WITH REMOTE SENSOR DATA." VOL. 964. US GOVERNMENT PRINTING OFFICE, 1976.
- BENZ, URSULA C., ET AL. "MULTI-RESOLUTION, OBJECT-ORIENTED FUZZY ANALYSIS OF REMOTE SENSING DATA FOR GIS-READY INFORMATION." ISPRS JOURNAL OF PHOTOGRAMMETRY AND REMOTE SENSING 58.3 (2004): 239-258.
- BEUCHER, SERGE. "THE WATERSHED TRANSFORMATION APPLIED TO IMAGE SEGMENTATION." SCANNING MICROSCOPY-SUPPLEMENT (1992): 299-299.
- BLASCHKE, THOMAS. "OBJECT BASED IMAGE ANALYSIS FOR REMOTE SENSING." ISPRS JOURNAL OF PHOTOGRAMMETRY AND REMOTE SENSING 65.1 (2010): 2-16.
- BORSOTTI, M., PAOLA CAMPADELLI, AND RAIMONDO SCHETTINI. "QUANTITATIVE EVALUATION OF COLOR IMAGE SEGMENTATION RESULTS." PATTERN RECOGNITION LETTERS 19.8 (1998): 741-747.
- BUDDHIRAJU, KRISHNA MOHAN, AND IMDAD ALI RIZVI. "COMPARISON OF CBF, ANN AND SVM CLASSIFIERS FOR OBJECT BASED CLASSIFICATION OF HIGH RESOLUTION SATELLITE IMAGES." GEOSCIENCE AND REMOTE SENSING SYMPOSIUM (IGARSS), 2010 IEEE INTERNATIONAL. IEEE, 2010.
- CANTY, MORTON J. "BOOSTING A FAST NEURAL NETWORK FOR SUPERVISED LAND COVER CLASSIFICATION." COMPUTERS & GEOSCIENCES 35.6 (2009): 1280-1295.
- CHEN, SHENG, ET AL. "SEGMENTATION OF MULTI-SPECTRAL SATELLITE IMAGES BASED ON WATERSHED ALGORITHM." KNOWLEDGE ACQUISITION AND MODELING, 2008. KAM'08. INTERNATIONAL SYMPOSIUM ON. IEEE, 2008.
- CONGALTON, RUSSELL G. "A REVIEW OF ASSESSING THE ACCURACY OF CLASSIFICATIONS OF REMOTELY SENSED DATA." REMOTE SENSING OF ENVIRONMENT 37.1 (1991): 35-46.
- DARWISH, AHMED, KRISTIN LEUKERT, AND WOLFGANG REINHARDT. "IMAGE SEGMENTATION FOR THE PURPOSE OF OBJECT-BASED CLASSIFICATION." INTERNATIONAL GEOSCIENCE AND REMOTE SENSING SYMPOSIUM. VOL. 3. 2003.

- DE SMET, PATRICK, AND RUI LUIS VPM PIRES. "IMPLEMENTATION AND ANALYSIS OF AN OPTIMIZED RAINFALLING WATERSHED ALGORITHM." ELECTRONIC IMAGING. INTERNATIONAL SOCIETY FOR OPTICS AND PHOTONICS, 2000.
- FERRAZZOLI, PAOLO, LEILA GUERRIERO, AND GIOVANNI SCHIAVON. "EXPERIMENTAL AND MODEL INVESTIGATION ON RADAR CLASSIFICATION CAPABILITY." IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING 37.2 (1999): 960-968.
- GENELETTI, D., AND B. G. H. GORTE. "A METHOD FOR OBJECT-ORIENTED LAND COVER CLASSIFICATION COMBINING LANDSAT TM DATA AND AERIAL PHOTOGRAPHS." INTERNATIONAL JOURNAL OF REMOTE SENSING 24.6 (2003): 1273-1286.
- HARALICK, ROBERT M., AND KARTHIKEYAN SHANMUGAM. "TEXTURAL FEATURES FOR IMAGE CLASSIFICATION." IEEE TRANSACTIONS ON SYSTEMS, MAN, AND CYBERNETICS 6 (1973): 610-621.
- HE, KAIMING, ET AL. "SPATIAL PYRAMID POOLING IN DEEP CONVOLUTIONAL NETWORKS FOR VISUAL RECOGNITION." EUROPEAN CONFERENCE ON COMPUTER VISION. SPRINGER INTERNATIONAL PUBLISHING, 2014.
- HEERMANN, PHILIP DALE, AND NAHID KHAZENIE. "CLASSIFICATION OF MULTISPECTRAL REMOTE SENSING DATA USING A BACK-PROPAGATION NEURAL NETWORK." IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING 30.1 (1992): 81-88.
- HUSSAIN, MASROOR, ET AL. "CHANGE DETECTION FROM REMOTELY SENSED IMAGES: FROM PIXEL-BASED TO OBJECT-BASED APPROACHES." ISPRS JOURNAL OF PHOTOGRAMMETRY AND REMOTE SENSING 80 (2013): 91-106.
- JING, FENG, ET AL. "UNSUPERVISED IMAGE SEGMENTATION USING LOCAL HOMOGENEITY ANALYSIS." CIRCUITS AND SYSTEMS, 2003. ISCAS'03. PROCEEDINGS OF THE 2003 INTERNATIONAL SYMPOSIUM ON. VOL. 2. IEEE, 2003.
- KAVZOGLU, TASKIN. "INCREASING THE ACCURACY OF NEURAL NETWORK CLASSIFICATION USING REFINED TRAINING DATA." ENVIRONMENTAL MODELLING & SOFTWARE 24.7 (2009): 850-858.
- MAGGIORI, EMMANUEL, ET AL. "CONVOLUTIONAL NEURAL NETWORKS FOR LARGE-SCALE REMOTE-SENSING IMAGE CLASSIFICATION." IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING (2016).

- MAS, J. F., AND J. J. FLORES. "THE APPLICATION OF ARTIFICIAL NEURAL NETWORKS TO THE ANALYSIS OF REMOTELY SENSED DATA." *INTERNATIONAL JOURNAL OF REMOTE SENSING* 29.3 (2008): 617-663.
- MOODY, DANIELA I., ET AL. "LAND COVER CLASSIFICATION IN FUSED MULTISENSOR MULTISPECTRAL SATELLITE IMAGERY." 2016 IEEE SOUTHWEST SYMPOSIUM ON IMAGE ANALYSIS AND INTERPRETATION (SSIAI). IEEE, 2016.
- MYINT, SOE W., ET AL. "PER-PIXEL VS. OBJECT-BASED CLASSIFICATION OF URBAN LAND COVER EXTRACTION USING HIGH SPATIAL RESOLUTION IMAGERY." *REMOTE SENSING OF ENVIRONMENT* 115.5 (2011): 1145-1161.
- NIU, XIN, AND YIFANG BAN. "MULTI-TEMPORAL RADARSAT-2 POLARIMETRIC SAR DATA FOR URBAN LAND-COVER CLASSIFICATION USING AN OBJECT-BASED SUPPORT VECTOR MACHINE AND A RULE-BASED APPROACH." *INTERNATIONAL JOURNAL OF REMOTE SENSING* 34.1 (2013): 1-26.
- OMKAR, S. N., ET AL. "URBAN SATELLITE IMAGE CLASSIFICATION USING BIOLOGICALLY INSPIRED TECHNIQUES." 2007 IEEE INTERNATIONAL SYMPOSIUM ON INDUSTRIAL ELECTRONICS. IEEE, 2007.
- QIAN, YUGUO, ET AL. "COMPARING MACHINE LEARNING CLASSIFIERS FOR OBJECT-BASED LAND COVER CLASSIFICATION USING VERY HIGH RESOLUTION IMAGERY." *REMOTE SENSING* 7.1 (2014): 153-168.
- REMBOLD, F., AND F. MASELLI. "ESTIMATING INTER-ANNUAL CROP AREA VARIATION USING MULTI-RESOLUTION SATELLITE SENSOR IMAGES." *INTERNATIONAL JOURNAL OF REMOTE SENSING* 25.13 (2004): 2641-2647.
- RIZVI, IMDAD ALI, AND B. KRISHNA MOHAN. "OBJECT-BASED IMAGE ANALYSIS OF HIGH-RESOLUTION SATELLITE IMAGES USING MODIFIED CLOUD BASIS FUNCTION NEURAL NETWORK AND PROBABILISTIC RELAXATION LABELING PROCESS." *IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING* 49.12 (2011): 4815-4820.
- SAARINEN, KARI. "COLOR IMAGE SEGMENTATION BY A WATERSHED ALGORITHM AND REGION ADJACENCY GRAPH PROCESSING." *IMAGE PROCESSING, 1994. PROCEEDINGS. ICIP-94., IEEE INTERNATIONAL CONFERENCE. VOL. 3. IEEE, 1994.*

- VATSAVAI, RANGA RAJU, ET AL. "MACHINE LEARNING APPROACHES FOR HIGH-RESOLUTION URBAN LAND COVER CLASSIFICATION: A COMPARATIVE STUDY." PROCEEDINGS OF THE 2ND INTERNATIONAL CONFERENCE ON COMPUTING FOR GEOSPATIAL RESEARCH & APPLICATIONS. ACM, 2011.
- VINCENT, LUC, AND PIERRE SOILLE. "WATERSHEDS IN DIGITAL SPACES: AN EFFICIENT ALGORITHM BASED ON IMMERSION SIMULATIONS." IEEE TRANSACTIONS ON PATTERN ANALYSIS AND MACHINE INTELLIGENCE 13.6 (1991): 583-598.
- WALTER, VOLKER. "OBJECT-BASED CLASSIFICATION OF REMOTE SENSING DATA FOR CHANGE DETECTION." ISPRS JOURNAL OF PHOTOGRAMMETRY AND REMOTE SENSING 58.3 (2004): 225-238.
- WANG, L., W. P. SOUSA, AND P. GONG. "INTEGRATION OF OBJECT-BASED AND PIXEL-BASED CLASSIFICATION FOR MAPPING MANGROVES WITH IKONOS IMAGERY." INTERNATIONAL JOURNAL OF REMOTE SENSING 25.24 (2004): 5655-5668.
- WILKINSON, GRAEME G. "RESULTS AND IMPLICATIONS OF A STUDY OF FIFTEEN YEARS OF SATELLITE IMAGE CLASSIFICATION EXPERIMENTS." IEEE TRANSACTIONS ON GEOSCIENCE AND REMOTE SENSING 43.3 (2005): 433-440.
- 安藤岳洋, 大西暁生. "高分解能衛星画像 GEOEYE-1 を用いた詳細土地被覆情報の取得精度検証と分類手法の比較 -港北ニュータウンを対象として- ." 日本都市計画学会都市計画報告書 No.14 (2015)
- 伊東里保, 飯野翔太, 藤田藍斗, 今泉友之, 彦坂修平. "ディープラーニングを適用した衛星画像からの土地被覆分類手法の評価." 人工知能学会第 30 回全国大会 (2016).
- 伊藤陽介, 大松繁. "競合型ニューラルネットワークによる土地被覆分類法." 写真測量とリモートセンシング 35.3 (1996): 5-17.
- 越智士郎. "画像オブジェクトに基づく高分解能衛星画像での土地被覆分類手法の検討." (2009).
- 岡谷貴之. "機械学習プロフェッショナルシリーズ 深層学習." (2015).
- 沖一雄, 大政謙次, 稲村實. "ミクセル分解による植生リモートセンシングのための植生被覆率と活性度の分離 室内実験におけるミクセル分解手法の評価." 農業気象 58.1 (2002): 33-39.
- 河邑眞, 辻子裕二. "多段ニューラルネットワークによる人工衛星画像の土地被覆分類." 写真測量とリモートセンシング 34.1 (1995): 71-80.

- 橋本秀太郎ら. "多時期光学観測データを用いた高精度土地被覆分類手法の開発." 日本リモートセンシング学会誌 34.2 (2014): 102-112.
- 三富創, 松岡昌志, 山崎文雄. "最尤法を用いた空撮画像からの建物被害抽出とその早期被害把握への応用." 土木学会論文集 717 (2002): 137-148.
- 児島利治, 宝馨. "リモートセンシング画像の空間分解能と土地被覆分類精度の関係 -4 種の画像と低分解能化アルゴリズムを用いて-" 日本リモートセンシング学会誌 16.5 (1996): 23-37.
- 小阪尚子ら. "高分解能衛星画像のテクスチャ特徴量とスペクトル特徴量を用いたオブジェクト指向型林分タイプ分類." 写真測量とリモートセンシング 46.2 (2007): 27-36.
- 須崎純一, 柴崎亮介. "ミクセルの存在とトレーニングデータの代表性を考慮した時系列低空間分解能画像を用いた土地被覆分類手法." 写真測量とリモートセンシング 40.3 (2001): 14-24.
- 大屋優, 金盛克俊, 大和田勇人. "衛星画像の時系列データを用いた再帰的土地被覆分類手法の検討." 情報処理学会第 77 回全国大会 5 (2015): 07.
- 大西暁生, 前崎隆一. "オブジェクト分類手法による詳細土地被覆情報の取得と地表面温度の再現性に関する研究." 土木学会論文集 G (環境) 70.5 (2014): I_59-I_69.
- 竹内章司. "時系列データの最尤法分類における分類結果の安定化手法." 写真測量とリモートセンシング 31.2 (1992): 11-22.
- 中川恭兵, 村上拓彦. "オブジェクトベース画像分析による森林タイプ分類における分類手法ならびに特徴量選択に関する検討." (2012).
- 望月翔太, 村上拓彦. "機械学習法を用いた SPOT5/HRG データの土地被覆分類とその精度比較." 統計数理 64.1 (2016): 93-103.

- JAXA. 日本全国の土地被覆分類図の公開 (2016 年アクセス)
http://www.eorc.jaxa.jp/ALOS/lulc/lulc_jindex_v1602.htm
- ISCGM. 全球の土地被覆分類図の公開 (2016 年アクセス)
<https://globalmaps.github.io/glcnm.html>
- ESA. 全球の土地被覆分類図の公開 (2016 年アクセス)
http://due.esrin.esa.int/page_globcover.php
- GLCN. 全球の土地被覆分類図の公開 (2016 年アクセス)
http://www.glc.org/databases/lc_glcshare_en.jsp
- GLCF. 全球の土地被覆分類図の公開 (2016 年アクセス)
<http://glcf.umd.edu/data/lc>
- EEA. 全球の土地被覆分類図の公開 (2016 年アクセス)
<http://www.eea.europa.eu/data-and-maps/data/global-land-cover-2000-europe>
- USGS. 全球の土地被覆分類図の公開 (2016 年アクセス)
<https://lta.cr.usgs.gov/GLCC>
- GSJ. 衛星データの無料公開サービス (2016 年アクセス)
<https://gbank.gsj.jp/madas/>
- SED. Terra 衛星搭載センサーのスペック公開 (2016 年アクセス)
http://www.sed.co.jp/sug/contents/satellite/satellite_aster.html
- SED. WorldView-3 衛星搭載センサーのスペック公開 (2016 年アクセス)
http://www.sed.co.jp/sug/contents/satellite/satellite_worldview3.html

付録

本研究では、手法の適用・検証にあたり、いくつかのプログラムコードを作成した。作成したプログラム一覧を以下に示す。

- セグメンテーション
 - マルチバンド画像から H-image の生成プログラム
 - Watershed アルゴリズムによるセグメンテーション処理プログラム
 - セグメンテーション画像の統合処理プログラム
 - セグメンテーション結果の教師無し評価プログラム
- クラス分類
 - データセット作成プログラム
 - ニューラルネットワークによるクラス分類プログラム
 - 最尤推定によるクラス分類プログラム
- その他
 - 画像の分割プログラム
 - 緯度・経度を指定して画像を切り出すプログラム
 - 入出力系プログラム

言語は手軽にデバッグが行えるスクリプト言語の中で、数値計算、ニューラルネット、画像処理のライブラリが充実している Python を選択した。Python のバージョンは当時最新の 3.5.1 を利用した。本研究でプログラムを実行したパソコンのスペックは、CPU が Intel Core i7-4790、メモリ 8GB であった。作成したプログラムコードは GitHub と呼ばれるプログラムコード共有サービスに公開した。

公開 URL: <https://github.com/yizumi1012xxx/land-use-classification>

謝辞

本研究に取り組むにあたり、多くの方のご指導・ご協力を頂きました。ここに感謝の意を記します。

主査の布施孝志准教授には、研究を進める上で大変お世話になりました。研究テーマをなかなか決められない私のために何度も打ち合わせをして頂き、その度にアドバイスを頂きました。研究をまとめ上げることができたのは先生のおかげだと確信しております。

副査の羽藤英二教授には、一歩離れた視点からのアドバイスを頂き、研究方針について改めて考える機会を頂きました。

清水英範教授には、研究室ゼミでアドバイスを頂きとても勉強になりました。また、研究室の飲み会では、様々なお話を聞かせて頂きとても楽しかったです。中西航前助教には、研究に関するアドバイスにとどまらず、研究室運営など様々な形でお世話になりました。私が初めて研究室を訪れた際には、石川さんと温かく迎えて頂いたことをよく覚えております。他にも、スポーツコンテストを通して普段の研究とは違った勉強もさせて頂きました。石田涼子秘書には、事務手続きにおいてお世話になりました。博士研究員の PEREZ Joan さんも短い間でしたがお世話になりました。英語が苦手な私に合わせてゆっくりと優しく話して頂き、とても嬉しかったです。

研究室の学生にも大変お世話になりました。

D2の神谷さんには、研究にとどまらず本当に様々なことを学ばせて頂きました。難解な理論や分析手法を神谷さんは分かりやすく説明してくれました。また、スポーツコンテストやディープラーニング基礎講座での経験はとても勉強になりました。昨年卒業した高橋さん、永良さん、平松さんにも大変お世話になりました。入学した頃の頃から、優しく接して頂き、本当に嬉しかったです。

同期の池澤君と原田君にも大変お世話になりました。池澤君とは論文提出直前にはよく一緒に途中まで帰り、お互いを励まし合いました。原田君は着々と進捗を生み出し、私をいい意味で焦らせてくれました。同期ではほぼ毎週行っていたゴルフは、研究で疲れた心を癒す時間となりとても楽しかったです。本当にありがとうございます。

後輩の皆さんにも大変お世話になりました。大倉君は研究や研究室運営を真面目に取り組んでおり、心から尊敬していました。福富君の社交的な姿にも常々感心していました。妹背君、佐藤さん、森田さん、横澤君も研究室に配属されて日が浅いにも関わらず、真摯に研究に取り組んでおりその姿に私は刺激を受けました。皆さん、この調子で頑張ってください。

大学で学び始めて、6年が経とうとしています。来年から社会人となりますが、これまでに学んだことを活かし社会に貢献していけたらと思います。最後に、様々な形で支援し続けてくれた両親に心より感謝します。